

分 类 号: U491
研究生学号: 2012442017

单位代码: 10183
密 级: 公 开



吉 林 大 学

硕 士 学 位 论 文

(学术学位)

基于视频的行人过街信号自适应优化方法研究

An adaptive optimization method of pedestrian crossing time based
on video detection

作者姓名: 关可汗

专 业: 交通信息工程及控制

研究方向: 智能交通

指导教师: 曲昭伟 教授

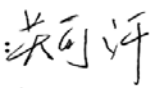
培养单位: 交通学院

2015 年 6 月

未经本论文作者的书面授权，依法收存和保管本论文书面版本、电子版本的任何单位和个人，均不得对本论文的全部或部分内容进行任何形式的复制、修改、发行、出租、改编等有碍作者著作权的商业性使用（但纯学术性使用不在此限）。否则，应承担侵权的法律责任。

吉林大学硕士学位论文原创性声明

本人郑重声明：所呈交学位论文，是本人在指导教师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期：2015 年 6 月 12 日

基于视频的行人过街信号自适应优化方法研究

An adaptive optimization method of pedestrian crossing time
based on video detection

作者姓名：关可汗

专业名称：交通信息工程及控制

指导教师：曲昭伟 教授

学位类别：工学硕士

答辩日期：2015 年 6 月 6 日

摘 要

基于视频的行人过街信号自适应优化方法研究

我国城市人口密集,居民步行出行占较大比例。同时随着机动化水平的提高,城市道路机非冲突愈加严重,行人作为弱势群体,其安全问题越来越受到人们重视,机动车与行人一旦发生碰撞,行人将受到严重伤害甚至死亡。当路段车流量较大时,不合理的行人过街信号设置,会因没有行人或行人较少,而浪费行人过街绿灯时间,白白造成机动车延误;又会因行人过多而造成行人过街绿灯时间不足,行人过街的安全问题无法保障。因此,研究有效的自适应行人过街信号方法对于保障行人安全,减少交通延误具有重要意义。

现阶段我国行人过街信号设置主要是定周期控制、手动按键式过街信号控制以及感应式控制。他们均以减少机动车延误为首要前提,且不能适应当前行人过街实际所需时间。本文针对以上问题,提出了基于视频的行人过街信号自适应优化方法,通过视频检测行人待过街区域,实时反馈采集数据,优化行人过街时间,保障了过街行人安全同时,提高了城市运行效率。

本文完成的主要工作和取得的研究成果如下:

◆ 改进的自适应背景模型

本文在背景差过程中,基于大津算法基础上提出了双阈值概念,相对于传统卡尔曼背景更新算法,本文获得了更优的背景更新阈值。针对背景易受到光照突变的影响问题,提出了强制背景更新方法,能够在背景灰度发生大面积变化时,迅速替换当前背景。通过实例验证分析,证明本文背景模型实用效果更好。

◆ 基于 SVR 的行人计数算法

本文首先利用前景像素点占屏比,进行行人密度预判,然后在不同行人密度下根据像素点数量统计特征和纹理特征属性择优进行特征表达,再通过图像分块模式消除“透视”的影响,进而引入 SVR 回归模型对样本集训练学习,构建目标函数,最后得到本文强健的行人计数 SVR 模型,有效预测待过街区域行人数量。通过实验效果对比,证明本文算法具有更好的行人计数准确度,鲁棒性和实时性均满足实用要求。

◆ 行人过街时间估计方法

针对现有行人过街信号无法满足行人过街时间需求,即过街时间不足或绿灯空放这一问题,本文充分考虑行人过街时间需求,分析不同时段行人数量与过街时间关系,以历史数据为训练样本,建立了本文基于 SVR 的行人过街时间估计方法,预测当前视频检测区域下等待过街行人所需过街时间。最后,通过对比实际行人过街时间,对本文算法性能进行评价。

关键词:

行人过街信号, 背景模型, 行人计数, 过街时间估计, SVR 回归模型

Abstract

An adaptive optimization method of pedestrian crossing time based on video detection

The city is densely populated in China, and residents travel on foot accounted for a large proportion. As the motorization level improving, the conflict between vehicles and pedestrians in urban road is more and more serious. As vulnerable groups, the pedestrians walking security has being payed more and more attention. In the case of collision between vehicles and pedestrians, pedestrians will be seriously injured or even death. When there are no pedestrians or less pedestrians in crosswalk and the road traffic in a high flow, owing to the unreasonable pedestrian crossing signal, the pedestrian green time is wasted and then caused vehicles delay. In addition, if pedestrian number is larger while pedestrian green time is insufficient, the crossing pedestrian security will can't be guaranteed. Therefore, researching on adaptive pedestrian crossing signal method is important for ensuring pedestrian security and reducing delays.

At present, pedestrian signal setting in our country mainly includes fixed cycle control, manual button type and induction control. Above the three types aim to reduce vehicle delay, but unable to satisfy the actual time required for pedestrian crossing. In view of the above problems, this paper puts forward the pedestrian crossing signal adaptive optimization method based on video, and detects the area where pedestrians are waiting to cross the street, collects real-time data. The method optimizes pedestrian crossing time, guarantees the security of the pedestrians crossing the street, and also improves the urban traffic efficiency.

The main work and achievements are as follows:

◆ Improved adaptive background model

In the process of background subtraction, this paper proposes double threshold concept based on dajin algorithm. Compared with the traditional kalman background update algorithm, this paper obtained a better background updating threshold. In response to the problem of background is susceptible influenced by illumination mutation, mandatory background updating method is proposed. When great changes have taken place in background gray area, the current background will be quickly replaced. Verified by examples analysis, this paper improves a better background model.

◆ Pedestrian counting algorithm based on SVR

This paper using the ratio of foreground pixel point of the screen, distinguishes pedestrian density, and under the different pedestrian densities, conducts feature expression according to

the number of pixels statistical features and texture features attribute. And through the image block mode to eliminate the influence of "perspective", then introduces the SVR regression model to train learning sample set, constructs the objective function and finally obtains robust pedestrian counting SVR model. It can effectively predict the pedestrian numbers of waiting for crossing the street. By comparing with experimental results, shows that this algorithm has better pedestrian counting accuracy, robustness and real-time meet the practical requirements.

◆ Estimation method of the pedestrian crossing time

In view of the existing pedestrian signal method can't satisfy the demand of pedestrian crossing time, this paper fully considers the pedestrian crossing requirements and analyzes the relationship between the number of pedestrians and the crossing time in the different periods, then takes the historical data as training sample and proposes a pedestrian crossing time estimation model based on SVR. This paper can predict pedestrian crossing time in current detection region. Finally, by comparing with the actual time of pedestrians crossing the street, evaluate the performance of this algorithm.

Key words:

Pedestrian crossing signal, background model, pedestrian counting, estimation of crossing time, SVR regression model

目录	
第 1 章 绪论.....	1
1.1 课题来源.....	1
1.2 论文研究背景及意义.....	1
1.3 研究现状.....	2
1.4 研究思路与研究内容.....	4
1.4.1 研究思路.....	4
1.4.2 研究内容.....	5
1.5 小结.....	6
第 2 章 行人检测算法.....	7
2.1 检测区域设定.....	8
2.2 自适应背景模型.....	8
2.2.1 背景初始化算法.....	8
2.2.2 基于 kalman 算法的背景表达.....	9
2.2.3 改进的自适应背景更新算法.....	10
2.3 行人目标提取.....	16
2.4 阴影检测模型.....	17
2.5 实验结果分析.....	20
2.5.1 背景初始化实验效果.....	20
2.5.2 改进的卡尔曼背景更新实验效果	21
2.5.3 行人提取实验效果.....	22
2.5.4 阴影剔除实验效果.....	22
2.6 小结.....	23
第 3 章 行人过街数量检测算法.....	25
3.1 像素点数量统计特征.....	25

3.2 纹理特征.....	26
3.2.1 纹理的定义.....	26
3.2.2 纹理分析方法.....	27
3.2.3 灰度共生矩阵及其统计特征	27
3.2.4 LBP 特征	31
3.3 特征优选及图像分块.....	31
3.3.1 行人密度判别.....	32
3.3.2 图像分块方法.....	33
3.4 基于 SVM 的行人计数算法.....	34
3.4.1 SVM 工作原理.....	34
3.4.2 算法实现.....	38
3.5 实验效果分析.....	40
3.5.1 交叉验证实验效果	41
3.5.2 行人过街计数实验效果	44
3.6 小结.....	47
第 4 章 行人过街信号自适应优化方法	49
4.1 传统行人过街时间计算	49
4.2 行人过街信号优化模型	51
4.2.1 行人过街信号优化相关因素	51
4.2.2 基于 SVR 的行人过街时间估计.....	51
4.3 实验效果分析.....	55
4.3.1 行人过街时间估计效果	55
4.3.2 性能评价.....	57
4.4 小结.....	59
第 5 章 总结与展望.....	61

5.1 研究结论与成果.....	61
5.2 研究展望.....	61
参考文献.....	63
作者简介.....	67
致 谢.....	69

图目录

图 1.1	本文研究内容框架图.....	5
图 2.1	前景检测算法流程图.....	7
图 2.2	检测区域设定图.....	8
图 2.3	基于平滑序列背景初始化示意图	9
图 2.4	前景图像灰度直方图.....	11
图 2.5	传统算法获取阈值图.....	11
图 2.6	本文算法获取阈值图.....	13
图 2.7	无前景时背景灰度分布图.....	14
图 2.8	加入虚拟像素点灰度分布图.....	14
图 2.9	本文背景更新算法流程图.....	15
图 2.10	视频序列背景更新示意图.....	16
图 2.11	提取前景效果图.....	17
图 2.12	本文阴影检测算法流程图.....	18
图 2.13	种子像素点与相邻像素点.....	20
图 2.14	不同背景初始化方法效果图对比	21
图 2.15	本文改进的卡尔曼背景更新算法效果图	21
图 2.16	前景区域行人提取效果图.....	22
图 2.17	阴影剔除实验效果图.....	23
图 3.1	行人过街数量检测算法框架图.....	25
图 3.2	生成 GLCM 图	28
图 3.3	GLCM 角度选取图	29
图 3.4	生成 LBP 特征图	31
图 3.5	前景密度判别图.....	32
图 3.6	像素特征分块效果.....	33

图 3.7	纹理特征分块效果.....	34
图 3.8	SVR 实现过程图.....	39
图 3.9	基于像素点特征交叉验证效果图	42
图 3.10	基于纹理特征交叉验证效果图	43
图 3.11	基于密度判别的像素特征交叉验证效果	43
图 3.12	基于密度判别的纹理特征交叉验证效果	44
图 3.13	预测集 1 行人过街数量	45
图 3.14	预测集 2 行人过街数量	45
图 3.15	预测集 1 过街行人绝对误差对比图	46
图 3.16	预测集 2 过街行人绝对误差对比图	46
图 4.1	平面结构图.....	49
图 4.2	理想行人过街区域人数变化图	50
图 4.3	实际行人过街区域人数变化图	50
图 4.4	过街行人数量与时间关系图	52
图 4.5	行人过街时间估计方法专项设计思路图	52
图 4.6	分时训练模型图.....	53
图 4.7	样本集自学习交叉验证结果图	54
图 4.8	本文方法行人过街区域人数变化图	55
图 4.9	高峰时段行人过街数量与时间关系图	55
图 4.10	高峰时段预测行人过街时间图	56
图 4.11	平峰时段行人过街数量与时间关系图	56
图 4.12	平峰时段预测行人过街时间图	57
图 4.13	行人过街时间绝对误差对比图 1	58
图 4.14	行人过街时间绝对误差对比图 2	58

表目录

表 3.1	RBF 核函数下系统性能	41
表 3.2	Sigmoid 核函数下系统性能	41
表 3.3	RBF 核函数下系统性能	42
表 3.4	Sigmoid 核函数下系统性能	42
表 3.5	不同特征表达下交叉验证对比.....	44
表 3.6	行人过街数量检测算法性能评价 1	46
表 3.7	行人过街数量检测算法性能评价 2	47
表 4.1	不同参数下 SVR 过街时间模型性能.....	54
表 4.2	行人过街时间估计性能对比评价	58

第1章 绪论

1.1 课题来源

本学位论文依托于以下科研项目：

吉林省科技厅重点项目《基于视频的行人过街信号智能优化技术研究》，项目编号：20130206093SF。

1.2 论文研究背景及意义

20 世纪末以来，我国城市机动化水平显著提高，城市交通出行量飞速增长，人们在努力解决交通拥堵、提高城市运行效率的同时，交通安全问题成为不可避免的话题，特别是行人安全问题。据《道路安全全球现状报告 2013》显示，全球平均每天有近 4000 人因道路交通事故而丧生，其中大约 1/5 是行人，并且该伤亡人数有逐年增长态势。

行人在道路交通中作为弱势群体，一旦发生交通事故常常受到严重伤害甚至死亡。我国城市居民出行方式中，步行仍然占很大比例，在交通复杂的商业区，人、车抢行的状况经常发生，加上缺乏有效的安全管理设施，导致行人过街交通问题日益突出。当路段上车流量较大时，不合理的行人过街行为，极可能造成交通堵塞，降低了路网通行能力，严重制约社会经济发展，也对行人的生命财产安全造成威胁。如何保障行人安全、减少机动车延误成为亟待解决的问题。

通常情况下，没有行人或者行人数量过少时，导致行人过街绿灯时间浪费，机动车延误；行人数量过多时，导致行人过街绿灯时间不足，机动车与行人发生冲突，给行人带来安全隐患，都是因为信号灯设置不合理造成的。目前信号灯配时大多采用定周期配时，或者安装行人过街按钮人工控制绿灯启亮时间，但是无法满足人群过街所需时间，无法最大程度上发挥信号灯的功能，难以适应复杂的交通环境。从 20 世纪末以来，伴随着计算机、数字图像处理等技术的迅猛发展，智能交通领域也获得了长足的进步。智能交通融入了视觉信息，通过视频监控行人待过街区域，对监控返回的图像信息数据进行判断和分析，最终计算机做出合理的行人过街时间估计方案。

国内基于视频检测的人群密度估计方法^[1-3]多用于人口相对密集的车站、机场、大型商场、购物中心、旅游景点等公共场所，根据获得的人群密度在相应阈值范围内进行预警，预防因人数过多造成公共安全事故，目前尚无基于视频检测的行人过街时间估计方法。“中国式过马路”这一现象从侧面反应出中国城市交通中，行人信号控制的弊端，基于行人数量的过街时间估计方法的研究与应用，对满足行人过街需求，保障行人生命安全，减少行人延误，提高城市综合运行效率具有重要意义。

1.3 研究现状

基于行人数量的过街时间估计方法是智能交通领域不可缺少的组成部分，一面能够协调行人与车辆之间有序高效运行，另一面将带来巨大的市场利益。从技术角度分析，大致可以分为三个主要部分。首先，根据设备应用条件建立完备的背景模型；然后，利用图像处理技术和分类器实现对当前图像中行人数量有效估计；最后，由行人数量预测最佳的行人过街时间。国内外学者在实现算法上进行了大量研究工作。鉴于此，本文从三个技术方面介绍有关基于行人数量的过街时间估计方法的国内外研究现状。

(1) 背景建模方面

背景模型的相关算法已经趋于成熟，但是算法的精度、速度以及适应性仍然有很多能够改进的空间，同时背景模型的优劣很大程度上影响上层算法能否实现的问题。李志慧^[4]等针对背景在时间序列上搜索平滑子序列，统计相对稳定时间段内的背景图像，结合中值法初始化背景。与其它背景初始化算法相比，该方法有效应对缓慢移动的前景，并且解决前景物体过多时初始化失效等问题。叶锋^[5]等人在平均值法背景更新^[6]的基础上，加入了背景学习因子，以改变背景更新的速率。该方法虽然计算简单，但是前景覆盖率较大时背景更新会失效。Feng Wang^[7]基于混合高斯模型将像素分成背景、动态背景、移动物体、临时对象四类进行更新，实验证明该方法相对于传统算法减少了计算复杂程度，有较好的背景更新效果。李明之^[8]基于混合高斯模型，针对由光照突然变化导致的背景失效问题提出了分情况更新方法。该方法能够处理全屏光照变化的背景更新问题，但是当前景物体过多过大时，即超出判断光照变化阈值时，该方法失效。Scott, J. Pusateri^[9]基于卡尔曼滤波算法实时背景更新，在昼夜以及天气变化时能够及时更新背景，实验显示效果良好。Saeed Kamel^[10]应用卡尔曼与范例纹理合成相结合方法进行更新。国内哈尔滨工业大学的盛遵冰^[11]分析了高斯滤波原理，提出了自适应学习速率的高斯背景更新算法，结果显示背景更新速度快且有效。赵发科^[12]采用四邻域帧差法填充了前景“空洞”，较好的保留了背景更新区域，使背景更新更加完整。

(2) 行人计数方面

目前基于视频的行人检测^[13-16]与人群计数方法逐渐成为各国研究机构、大学及企业研究的热点。A.N. Marana^[17]等人于 1997 年提出了基于纹理 GLDM 特征的人群密度估计算法。在视频场景中，检测人群图像的 GLDM 特征，根据特征出现复杂情况与事先人为制定规则相比较，自动判断当前监控下的人群密度。1998 年麻省理工学院 Papageorgiou^[18]教授等人首次提出了采用滑动窗口的检测方法，用不同角度的 Haar 特征与 SVM 相结合，对大量人脸样本图像分类学习进行行人检测，虽然实际检测准确率达到工程应用标准，但是其理论研究意义深远。2001 年 Paul viola^[19]和 Michael Jones 两位学者在已有算法基础上提出利用积分图像快速提取 Haar-like 特征，并通过 Adaboost 级联分类器训练学习行人样本，其检测速度和准确率有一定提高，这一思想对后来学

者们对行人检测算法的改进奠定了基石。法国学者 Navneet Dalal^[20]和 Bill Triggs 两人受到 SIFT 算子的启发,于 2005 年提出了梯度直方图(Histogram of Oriented Gradient, HOG)特征的行人检测算法,就单个特征而言, HOG 是目前最有实用性的,但是在人群数量密集的场合发生行人遮挡问题却不能有效的检测。鉴于此,之后很多算法将 HOG 与其他行人特征相结合,例如 HOG+LBP(局部二值模式)特征,经大量实验分析,多特征相结合的行人特征描述算子更加有效。加拿大西蒙弗雷泽大学 Sabzmeydani^[21]在 2007 年提出了基于 shapelet 特征的行人检测算法,算法最大进步之处是大大降低了行人检测误检率,并能够自动生成行人特征,特征又通过支持向量机学习,是对机器学习方法更加深入的应用。俄罗斯莫斯科国立大学的 Olga Barinova^[22]等人在 2010 年提出基于 Hough 变换的行人检测算法,在检测准确率与解决遮挡等问题上有了较好的提高。1973 年,研究人员 Haralick^[23]开创性的提出了著名的 gray-Level co-occurrence matrix(GLCM),又称灰度共生矩阵。GLCM 建立在图像像素联合概率密度基础上,包含了大量的纹理信息,反应出图像的亮度、位置关系、变化幅度等信息。之后很多学者在此基础上进行改进,在 GLCM 的 14 个纹理特征中选择 4 个具有代表性的特征,适当减少目标图像灰度级加快计算机处理速度。本论文行人特征提取中同样应用了 GLCM 特征。2014 年 TRFICON 公司开发的行人检测设备 safewalk(1)应用在英国伦敦街头,其系统 SCOOT 首次用于行人过街引导,能够自动识别等待过街人数与道路排队车辆数,根据人数与车辆数合理“安排”行人过街时间。该系统用来替代交警工作,调整伦敦交通流量,预期城市交通延误减少 12%。

尽管国外学者对行人检测技术研究较早,研究方法繁多,在相关领域有很深的理论基础,取得了显著的成果。但没有针对性的面向我国交通发展状况,不能满足我国交通实际需要。我国城市人口密集,机动车保有量大,是典型的混合交通国家。

相对于发达国家,我国视频检测行人技术起步略晚,但随着经济建设的蓬勃发展,社会对智能交通的需要,我国众多学校、科研人员以及企事业单位纷纷投入到相关领域中,在国外现有经典算法上进行很多改进,在一定条件下,检测效果较好,如吉林大学胡宏宇^[24]等人以灰度共生矩阵为特征,考虑空间分布特性,在图像上进行分块处理,利用支持向量机(SVR)构建行人图像特征与人群数量之间的拟合关系,最终达到有效估计人群的目的。李寅^[25]提出结合小波变换和灰度共生矩阵的特征描述算子,对图像局部以及全局特征进行分析处理,用 SVM 训练学习,最后得到人群密度模型。刘福美^[26]提出了基于像素点和纹理特征的人群密度估计算法,在不考虑光照变化条件,对人群数量分段拟合,结合支持向量机的训练,得到简单高效的人群密度估计方法。武博^[27]由人体部位曲线自定义三种 edgelet,包括对称、弧形和直线型,囊括了人体主要轮廓,通过 adaboost 算法筛选出最有效的 edgelet 描述行人,再对比图像中任意位置,如果返回的响应值高,则证明图像中图形与特征描述子相近,前景物体为人体的概率就大。哈尔滨工业大学^[28]用边缘检测 Canny 算子与纹理特征结合的方法,分成多种人群密度,

结合支持向量机训练样本，预测人群密度。中国科学院重庆绿色智能技术研究院覃勋辉^[29]用 *simile* 分类器对已进行分块的子图像先进局部二值模式(ALBP)优化，再采用回归分析模型建立子图像块与人数关系，有效地估计人群数量。

(3) 行人过街时间方面

徐良杰^[30]等人分析了转弯机动车对过街行人的影响，推导出穿越机动车人数和待过街人数，最后建立行人过街时间模型，并给出了行人平均过街时间的相对误差和绝对误差。Wael ALHAJYASEEN^[31]考虑了人行横道对向行人之间的影响以及人行横道宽度，建立了基于空气动力阻力理论的行人过街时间模型。刘光新^[32]等人依据不同条件如，红灯时间、车道数、以及过街行人年龄为参考因素，不考虑行人性别情况下，得出不同过街等待区域行人过街最大忍耐时间。赵韩涛^[33]研究有行人专用相位交叉口行人过街时间，借助 HCM 模型，在大量数据统计之后，建立了不同穿越方式的过街时间和位速度模型，该模型能够预测实际行人过街时间，且误差较小。钟章建^[34]从感应控制和协调信号控制两个方面入手，对路段行人过街信号控制方法进行研究，并通过软件实现算法。

众多研究单位和学者在背景建模方面、行人计数方面进行了大量研究工作，并取得了实质性进展，例如大部分监控应用在行人出行量较大的场合，单纯获得人群密度信息，进行简单预警，并未通过人群数量实现其他功能。而在行人过街时间方面，国内尚无应用基于视频检测技术手段计算行人过街时间方法。通过对国内外研究现状的分析，本文在众多学者研究基础上，结合视频检测行人计数算法对估计行人过街时间方法进行研究。

1.4 研究思路与研究内容

1.4.1 研究思路

本文以实时预测行人过街时间为目的，深入研究人群计数技术，通过视频实时获得行人数量，建立行人数量与过街时间的关系模型。考虑到摄像机静止，本文采用背景差法得到前景运动目标，本文提出的改进的卡尔曼背景更新算法对背景实时更新，通过阴影去除手段得到前景行人目标；灰度图像像素点与纹理特征作为行人描述算子，结合空间分布特征，对图像进行分块处理，利用支持向量回归(SVR)训练学习，构建行人计数模型；经大量调查得到的人群数量与行人过街时间历史数据通过 SVR 模型拟合，建立行人过街时间估计方法。本文基于 SVR 的行人过街时间估计方法旨在精准预测行人过街所需时间，满足过街需求，保障行人安全。同时，为行人信号配时方法提供技术支持，有效减少行人与机动车延误。

综上所述，本文研究框架图如图 1.1 所示。




图 1.1 本文研究内容框架图

1.4.2 研究内容

依据本文研究框架图，内容安排如下：

第一章：绪论。介绍了本论文研究的背景、意义、各章节内容，以及完成本论文所依托的课题，在阅读了大量文献与国内外相关著作之后，总结有关基于视频行人计数研究现状，针对我国混合交通行人过街信号设置不合理这一问题，提出了本学位论文的技术思路和整体结构。

第二章：行人检测算法。首先，在视频监控下根据行人过街等待区域确定感兴趣区域，分析了不同背景模型的适用条件，选择最佳的背景初始化算法。然后，总结现有背景更新算法的优缺点，以及更新效果难以满足后续图像处理的要求。本文改进了基于卡尔曼滤波的自适应背景更新方法，提出了双阈值与虚拟像素点概念，结合现有大津算法（Otsu）进行前景目标提取。最后，针对前景区域周围存在阴影问题，从 RGB 颜色信息方面分析阴影属性，构造基于颜色变化度的阴影去除模型，达到提高前景目标检测效果的目的。

第三章：人过街数量检测算法。本章作为实时计算行人数量的核心章节，主要阐述了根据提取特征属性的不同，建立像素特征与纹理特征结合的特征表达方法，该方法优点在于能够预先通过前景像素点数量提取合适的行人特征。考虑到行人数量变化、视频检测行人区域很大，将视频检测行人区域进行分块处理，以抵消“透视”效果造成的误差，最后设计基于支持向量机的多类别分类器学习机制，实现了实时计算行人数量。

第四章：行人过街时间估计方法。本章主要目的是对现有行人过街时间设置无法满足行人实施过街的需求而改进，主要方法是基于视频手段，依靠已知实时行人数量，分析行人数量与过街时间关系，利用 SVR 原理提出了过街时间模型。该模型自动设置当前人数下的最佳的过街时间，避免绿灯空放或过街时间不足等现象发生。

第五章：论文总结与展望。本章对本学位论文的研究进行了全面的总结，梳理研究取得的主要成果，并通过大量的数据调查和编程测试，发现模型存在的不足，在此基础上展望下一步研究工作的方向和计划。

1.5 小结

行人与车辆冲突愈发严重的今天，行人信号设置不合理已经严重影响交通运行效率。在国内交规规定机动车应当避让行人虽然合理，但没有有效的强制措施加以保证，再加上行人过街安全设施缺乏、标识不清，过街行人的人身安全受到严重威胁。本文针对这一问题从源头入手，研究利用视频检测手段对行人过街信号自适应优化方法研究，确定了本文的技术路线和研究内容，具体方法将在以下章节进行阐述。

第2章 行人检测算法

行人检测^[35]是本文框架中第一部分，其通常作为基础算法在各种系统底层服务，算法的准确性以及鲁棒性经常受到各种条件的制约。优良的行人检测算法在保证系统可靠性的同时，能够为后续高层算法提供提升性能的空间。本文应用背景差分^[36]方法进行行人检测，对比分析现有背景更新算法的不足，构造自适应背景模型，改进了 kalman 背景更新算法，同时该算法为行人目标提取提供依据，最后在前景基础上分析图像 RGB 颜色对比度，构建阴影检测模型^[37]，从而去除阴影，提高行人检测效果。经实际场景截取视频进行验证，该算法对比已有算法在背景更新和行人检测效果上提升明显。本文行人检测算法流程图如下图 2.1 所示。




图 2.1 行人检测算法流程图

2.1 检测区域设定

提取检测区域，即提取感兴趣区域。可以依照行人等待过街范围合理设置视频检测区域，这样在很大程度上减少硬件资源浪费，重要的是提高系统运行速度，增强实用性。如图 2.2 所示。



图 2.2 检测区域设定图

检测区域设定范围因视频检测场景而异，便于快速检测行人目标。

2.2 自适应背景模型

欲获得稳定的目标图像，首先要获得背景图像，这就考验背景的实时性与鲁棒性，主要表现在能够最大限度上应对复杂的环境变化。背景模型主要有背景初始化与背景更新两个部分内容。背景初始化是背景更新的前提，在一段视频序列中提取近似背景图像，背景更新是背景初始化的延续，保证背景实时完整，是检测行人目标的基础。

2.2.1 背景初始化算法

背景初始化受前景元素影响较大，前景行人密度越大且滞留时间越长对背景初始化算法要求就越高。常用的初始化算法有多种，有：

(1) 平均值法

平均值法是最简单常见的提取初始背景方法。算法的思想是一段视频在时间序列上将各个像素点的平均值作为初始背景。其算法简单，计算速度快，对于前景目标密度较小情况适用，如前景中有人群缓慢移动时，平均值法提取背景将失效。公式如下：

$$Background(i, j) = ave\{pixel_1(i, j) + pixel_2(i, j) + \dots + pixel_n(i, j)\} \dots\dots (2.1)$$

式中， $Background$ 为背景初始化图像； $pixel(i, j)$ 为图像坐标点的灰度值； n 为时间序列长度。

(2) 基于灰度直方图统计法

基于灰度直方图统计法是一段视频在时间序列上统计每个坐标点，每点灰度值出现频数最大的值作为该点的背景值。该算法仍然仅对前景密度较小情况下适用，一旦前景行人数量增多，初始背景的统计值将失效。公式如下：

$$Background(i, j) = \max\{hist(0), hist(1), \dots, hist(255)\} \dots\dots\dots (2.2)$$

式中，*Background* 为背景初始化图像；*hist* 为统计出现的灰度值。

(3) 基于平滑序列的背景初始化方法

在本文研究内容中，前景是行人，背景是地面。前景与背景在图像上最大的区别是前景的像素灰度值不稳定，而背景的像素灰度值却是相对稳定不变的。根据时间序列上背景灰度呈现平滑序列这一特征，采用可变滑动窗口检测图像像素的平滑序列，当一定长度窗口内的像素灰度值满足阈值限定范围内，则认为该窗口内的序列为平滑序列，作为背景样本。再通过聚类识别的思想，构建多个平滑序列组合，取其中值作为最终背景，完成背景初始化。

此方法虽然处理速度略慢，但是却能够解决前景率大于 50% 的复杂情况，克服了其他方法遇到复杂场景时初始化失效的问题，完全满足工程上的实用要求。图 2.3 为基于平滑序列背景初始化示意图。




图 2.3 基于平滑序列背景初始化示意图

2.2.2 基于 kalman 算法的背景表达

目前，背景表达方法已经趋于成熟，有简单的基于遗忘因子方法^[38]，单高斯方法与混合高斯方法^[39]。基于遗忘因子方法计算简单，计算机处理快，实时性好，但无法满足行人目标过多情况使用；单高斯方法虽然效果较好，但是不能应对背景复杂变化的情况；混合高斯能够克服大部分环境变化，但算法预先设置参数过多，更新背景速度阈值需手动设定，限制了背景更新性能。

在基于平滑序列的背景初始化基础上，本文利用卡尔曼算法进行背景表达与更新过程。卡尔曼滤波器原理简单以及稳定性好，已经被广泛应用在各个领域。在智能交通中，卡尔曼滤波可以用来进行背景更新，更重要的是，还能有效地对未来背景进行合理判断与预测，这在很大程度上确保了背景更新的实时性与精准度。

在背景更新过程中，kalman 滤波对背景状态进行实时预测与更新，根据工作原理，有如下公式：

$$\begin{cases} B(x, y, t) = B(x, y, t-1) \\ P(x, y, t) = P(x, y, t-1) + Q \end{cases} \dots\dots\dots (2.3)$$

$$\begin{cases} B(x, y, t) = B(x, y, t) + k(x, y, t)[I(x, y, t) - B(x, y, t)] \\ k(x, y, t) = P(x, y, t) / (P(x, y, t) + R) \\ P(x, y, t) = (1 - k(x, y, t))P(x, y, t) \end{cases} \dots\dots\dots (2.4)$$

式 (2.3) 是背景预测部分。

式中， $B(x, y, t-1)$ 为上一时刻背景最优值； $B(x, y, t)$ 为当前时刻背景预测值； $P(x, y, t-1)$ 为式中对应的协方差； $P(x, y, t)$ 是对协方差的预测； Q 为系统过程误差。

式 (2.4) 是背景更新部分。

式中， $B(x, y, t)$ 为现时刻背景最优值； $k(x, y, t)$ 为系统增益； $I(x, y, t)$ 为当前时刻背景值； R 为系统测量误差。

Kalman 滤波器是一种一阶稳态系统，在相对稳定状态下更新和预测背景。但是有行人目标出现时，扰乱了当前状态的稳定性，这是由于 kalman 背景更新算法的局限性导致背景更新失效。

2.2.3 改进的自适应背景更新算法

复杂的外界环境中经常出现天气问题导致光照突变，背景会随着光照的变化而变化，常常因背景更新不及时，背景被错误的当作前景检测出来。这时就需要背景更新算法及时有效的纠正错误，将原背景更新成已经变化的背景。又如，有前景物体长时间在视频检测窗口停留，需要将其融入到背景之中，而背景中分离的物体移出视频检测窗口，需要快速更新背景。上述问题是工程上实际出现的、亟待解决的难点，且处理不当将严重影响本文后续行人计数算法的准确性。因此，本文在总结现有算法基础上提出了改进的自适应背景更新算法，其中包括选择性背景更新和强制背景更新这两个概念。

2.2.3.1 选择性背景更新

选择性背景更新，是判断有行人的区域不更新背景，在没有行人的区域进行实时更新。公式如下：

$$B(x, y, t) = \begin{cases} B(x, y, t-1) & , M = 1 \\ B(x, y, t) + k(x, y, t) \cdot [I(x, y, t) - B(x, y, t)] & , M = 0 \end{cases} \dots\dots\dots (2.5)$$

式中， M 代表是否为前景行人区域。

选择性更新的阈值是在前景灰度上统计得到的，获取前景灰度公式为：

$$\Delta F(x, y, t) = C(x, y, t) - B(x, y, t-1) \dots\dots\dots (2.6)$$

式中， $\Delta F(x, y, t)$ 为前景灰度值； $C(x, y, t)$ 为当前帧灰度值； $B(x, y, t-1)$ 为背景灰度值。

前景图像灰度分布图如下。




图 2.4 前景图像灰度直方图

为了确定在 $M=0$ 时背景更新的阈值，通常做法是对前景图像做绝对值处理，再手动或自适应算法获得该阈值 T ，如图 2.5 所示。但是在前景正负灰度不对称的情况下，取绝对值必然导致数字信息的丢失，得到的阈值不能真实的反应背景信息。




图 2.5 传统算法获取阈值图

为此，本文对上述问题进行研究，提出了双阈值判断的概念，并针对一些特殊情况又提出虚拟像素点的概念，很好的解决了各种情况遇到的问题。

(1) 双阈值判断

双阈值判断建立在大津算法^[40]之上，大津算法就是在背景与前景目标两类中间找到一个最佳阈值 T ，该阈值使两类目标分错的概率最小，使类间方差最大。算法实现如下：

$$\begin{cases} \omega_0 = \frac{N_0}{M * N} \\ \omega_1 = \frac{N_1}{M * N} \\ g = \omega_0 * g_0 + \omega_1 * g_1 \\ \sigma = \omega_0 * (g_0 - g)^2 + \omega_1 * (g_1 - g)^2 \end{cases} \dots\dots\dots (2.7)$$

式中， ω_0 为前景点占图像比例； g_0 为前景平均灰度； ω_1 为背景点占图像比例； g_1 为背景平均灰度； N_0 为像素的灰度值大于阈值 T 的像素个数； N_1 为像素的灰度值小于阈值 T 的像素个数；图像的大小为 $M*N$ 。

带入 g 得最大图像类间方差：

$$\sigma = \omega_0 \omega_1 (g_0 - g_1)^2 \dots\dots\dots (2.8)$$

当从最小灰度 $T=0$ 遍历 255 个灰度，使图像类间方差 σ 最大时，此时的灰度值 T 就是自动获得分割图像的最佳阈值。当行人目标之间灰度差异很大时，由于算法本身不考虑图像局部灰度特征，而是纵览全局得出最合适的阈值，导致部分与背景灰度相近的前景被淹没在背景之中。

前景行人不可避免的有浅色和深色衣着同时出现在检测感兴趣区域中，行人中深色衣着的灰度常常与地面也就是柏油路灰度相当，背景差后再取绝对值得到的灰度值往往低于传统大津算法的检测阈值，尤其是浅色和深色衣着同时出现的情况，白色衣着行人的出现将该帧阈值“带”到很高，使前景深色衣着行人淹没在背景之中，非常不利于前景行人的提取。因此，本文不在背景差后进行绝对值处理，将差分后前景灰度图像分成正负两部分，分别进行大津算法。如图 2.6 所示，前景图像灰度直方图正负灰度分布不同，负数一边为行人衣着颜色低于地面灰度，正数一边为行人衣着灰度高于地面灰度，因高斯分布不同必然导致更新背景阈值不同。因此，本文在灰度分布直方图上进行两次大津算法，得到两个阈值 T_1 、 T_2 ，在阈值限制范围内进行背景更新。选择性背景更新表达式可以将 (2.5) 改写为：

$$B(x, y, t) = \begin{cases} B(x, y, t-1), & \text{if } \Delta F(x, y, t) > T_2 \cap \Delta F(x, y, t) < T_1 \\ B(x, y, t) + k(x, y, t) \cdot [I(x, y, t) - B(x, y, t)], & \text{else} \end{cases} \dots\dots\dots (2.9)$$




图 2.6 本文算法获取阈值图

(2) 虚拟像素点

当行人目标灰度相近且与背景差异较大时，大津算法有较好的图像分割效果。显然大津算法相对于手动设定阈值有自适应性，但是仍然无法满足复杂多变的交通状态。根据大津算法的特性，当行人目标和背景差异很小的情况下，也就是监控区域没有前景行人时，前景灰度统计直方图不再具有高斯分布特征，如果仍然采用大津算法寻求阈值必然造成部分背景被分割成前景，算法错误地寻找最大类间方差和，计算出错误的阈值。针对上述客观存在的问题，本文在大津算法基础上提出了虚拟像素点概念。下面对算法进行阐述。

考虑到算法本身，当视频检测区域没有前景行人图像时，视频序列当前帧与背景做差得到的图像绝大部分像素点灰度值为零，此时应该提取不到任何前景，但经过大津算法二值化的图像强制错误的在灰度值为零左右的点得到阈值，导致全图像出现噪声。为了抑制噪声，我们需要在图像另一端构造出虚拟的前景。从数学上看，加入新的高斯分布是为了大津算法能够找到分割图像的阈值，而又不破坏背景图像。本文算法在每幅处理的图像中加入给定的虚拟像素点，这些虚拟像素点加在像素灰度值稍大的点上。这些虚拟像素点不在图像中真正的存在，只是在计算得到阈值时遍历所有灰度中参与运算出现。作为虚拟像素点，其灰度值和数量两个参数设置尤为重要。需注意两点：

- 1 检测区域没有前景图像时，作为虚拟前景物体出现，保证自适应阈值在一个合理范围；
- 2 检测区域有前景图像时，虚拟像素点不会对自适应阈值造成影响。

如图 2.7 所示，某一帧无前景时背景灰度分布图，显然不符合大津算法图像分割的要求，做法是在灰度分布的另一端加入虚拟像素点，构造新的高斯分布，使图像具有可分性。加入虚拟像素点后的图像灰度分布图如图 2.8。




图 2.7 无行人时背景灰度分布图




图 2.8 加入虚拟像素点灰度分布图

为了使加入的虚拟像素点便于观察，在图 2.8 中截取了部分纵坐标。从图中灰度峰值可知，由于虚拟像素点的加入，构造出两个高斯分布，满足大津算法的应用要求，将计算得出的阈值作为背景更新范围反馈给 kalman 滤波器进行背景更新。

2.2.3.2 强制背景更新

在视频检测中，经常出现因天气问题造成光照亮度的突然变化，导致路面的灰度变化被当做行人错误的检测出来，需要将已经变化的背景快速更新过来，或者有长时间不动的背景从检测窗口中移动，需要背景及时强制更新。本文为了解决此类问题，在卡尔曼滤波中加入了强制背景更新时间 t ， t 是强制更新的等待帧数，通常视频帧率是 25fps/s，行人过街时间是 $t_a s$ ，即 t 取大于 $25t_a$ 帧就能满足更新时间要求，本算法采用 $t=t_{max}$ 作为强制背景更新等待时间。

本文背景更新算法流程图 2.9 所示，其基本流程是：

1. 视频第 1 帧与初始背景进行差分处理；
2. 背景更新一共有三部分组成：(1) 图像像素灰度值在阈值范围内进行 kalman 滤波，

强制更新等待帧数 t 清零；(2)不在阈值范围内 t 自加，如果没达到最大强制更新帧数用 $k-1$ 帧像素点做背景；(3)如果达到最大强制更新帧数用当前第 k 帧置换背景；

3.得到第 k 帧背景后返回 2，用视频 $k+1$ 帧与第 k 帧背景做差，反复循环 2、3 步骤。




图 2.9 本文背景更新算法流程图

其中， t_1 为上文正数阈值； t_2 为上文负数阈值； T 为差分处理的灰度差值。

本文采用上述背景更新算法，对拍摄的某一场景视频进行背景更新处理，考虑到算法应对光照变化因素以及验证算法适应性，所以视频拍摄时间是从下午直至傍晚时分，选择其中某一个像素点进行实验分析。如图 2.10 所示，蓝色线为该像素点在帧序列上的灰度值，绿色线为同一像素点实时背景更新的灰度值。可见，本文算法的背景更新结果与真实背景十分吻合。




图 2.10 视频序列背景更新示意图

2.3 行人目标提取

行人目标提取方法有很多种，最常用的方法有背景差法和帧差法，很多改进算法都是基于这两种经典算法实现的，例如三帧差法，帧差法与背景差结合法等。帧差法虽然能够较好应对背景中产生的噪声，但是对前景物体的运动速度适应性较差。在实际应用中，如行人过街等待时，行人相对背景处在静止或缓慢运动状态，此时帧差法不能有效检测出行人，导致行人提取失效。

分析本文行人信号自适应优化系统实际使用要求，本文采用背景差法提取行人区域。结合上节获得的实时背景更新图像，进行背景差法获取前景行人，再利用背景更新阈值得到二值化后的行人区域。由公式（2.6）可知，背景差分公式：

$$F(i, j, t) = \begin{cases} C(i, j, t) - B(i, j, t-1), & \text{if } C(i, j, t) > B(i, j, t-1) \\ B(i, j, t-1) - C(i, j, t), & \text{else} \end{cases} \quad \dots\dots (2.10)$$

式中， $F(i, j, t)$ 为行人目标； $C(i, j, t)$ 为当前帧图像； $B(i, j, t-1)$ 为背景图像。

二值化前景图像公式如下：

$$Fbw(i, j, t) = \begin{cases} 1, & \text{if } t_2 < F(i, j, t) < t_1 \\ 0, & \text{else} \end{cases} \quad \dots\dots\dots (2.11)$$

式中， $Fbw(i, j, t)$ 为二值化后的行人目标； $F(i, j, t)$ 为公式（2.10）中行人灰度目标； t_1 为上文提到的正数阈值； t_2 为上文提到的负数阈值。

图 2.11 中白色区域为行人目标，提取行人效果如图所示。




图 2.11 提取行人效果图

2.4 阴影检测模型

行人目标检测时，阴影常常伴随行人出现，影响行人目标检测质量，所以有必要对阴影部分检测与去除，提高行人目标检测性能。根据阴影的生成原因可以分成两类：投影和附影。附影是被检测物体因未受到光照一侧自身产生的阴影，对前景目标检测影响较小；投影是光源（例如阳光）被物体遮挡在地面形成的阴影，对前景目标检测影响较大。投影以噪声的形式被当做前景检测出来，严重影响前景目标检测效果。本文通过图像颜色信息对前景图像与阴影图像进行分析，得出了大量阴影区域数据，结合现有结论建立阴影检测模型。

因为阴影去除在前景目标检测中有着重要意义，近年来国内外一些学者对这一棘手问题进行了相关研究工作。R.Cucchiara^[41]等人研究发现人眼对颜色的区分与 HSV 颜色空间分量对应，相似度很高，遂将 RGB 颜色空间分量转换成 HSV 颜色空间分量之后进行阴影判别；JinMin Choi^[42]利用 RGB 颜色信息进行阴影预判，通过空间信息进一步确定阴影可能性，该算法能够快速识别阴影；中国民航大学张红颖^[43]提出 YCbCr 空间信息与混合高斯相结合的阴影检测与去除方法，能够在多种场景下快速去除阴影，提取前景目标。

由于实际交通信号设置是在露天环境，无法避免行人受到光照的影响在地面产生阴影。在参考相关文献的基础上，本文针对实际情况，以 RGB 颜色空间着手，考虑阴影、行人和背景之间的亮度差异、色度差异以及局部位置关系，通过大量的实验数据统计建立阴影检测模型。本节阴影检测算法流程图如图 2.12 所示。




图 2.12 本文阴影检测算法流程图

(1) 亮度差估计

由于光照受到行人遮挡在背景处形成阴影，阴影部分的 R、G、B 三个通道颜色亮度均低于相应背景亮度。所以，相同位置像素点的亮度大于背景的亮度就不可能是阴影点，因此可以确定该点是前景像素点，将其余像素点列为疑似阴影点。判断疑似阴影点亮度差估计约束条件如下：

$$Y(i, j, c) < B(i, j, c) \dots\dots\dots (2.12)$$

式中， Y 为疑似阴影像素点光照度； B 为背景像素点光照度； C 代表 R、G、B 三个颜色通道值。

实际检测图像中会夹杂着噪声，为了使疑似阴影点估计更加准确，更改约束条件为：

$$\begin{cases} B(i, j, r) - Y(i, j, r) > a_1 \\ B(i, j, g) - Y(i, j, g) > a_2 \\ B(i, j, b) - Y(i, j, b) > a_3 \end{cases} \dots\dots\dots (2.13)$$

式中， a_1, a_2, a_3 分别为 R、G、B 通道阈值。

通常情况，前景物体的亮度变化大于阴影变化，根据图像通道亮度统计发现，该变化服从 GMM 分布：

$$ave(c) = 1/N * \sum_{i,j,t} F(i,j,c,t), c=1,2,3 \dots\dots\dots (2.14)$$

$$\delta^2(c) = 1/N * \sum_{i,j,t} (F(i,j,c,t) - ave^2(c)), c=1,2,3 \dots\dots\dots (2.15)$$

式中, ave 为前景区域亮度均值; N 为总像素点数量; $F(i,j,c,t)$ 为对应通道在时间序列上的亮度值; δ^2 为每通道对应方差。

取 95%置信区间, 则亮度值分布在 $\pm 2.5\sigma$ 区域内认为是疑似阴影点, 公式如下:

$$\begin{cases} T_1(c) = ave(c) - 1.96 * \delta(c), c=1,2,3 \\ T_2(c) = ave(c) + 1.96 * \delta(c), c=1,2,3 \end{cases} \dots\dots\dots (2.16)$$

式中, T_1 、 T_2 为确定疑似阴影点阈值。

(2)色度差估计

通过亮度差估计, 前景被分割成了前景目标与疑似阴影区域, 然而在疑似阴影区域中还有部分前景像素点。色度差估计能够将疑似阴影区域的点进一步划分, 更加精确地提取出二次疑似阴影点。经过实验, R/G 分量比值变化在一定范围, 且 $B/(R+G+B)$ 值比背景大, 反映在色度上阴影比背景更蓝。综上得出色度差估计约束条件为:

$$T_3 < (Y(x,y,r)/Y(x,y,g)) / (B(x,y,r)/B(x,y,g)) < T_4 \dots\dots\dots (2.17)$$

$$1 < (Y(x,y,b)/Y(x,y,r)) / (B(x,y,b)/B(x,y,r)) < T_5 \dots\dots\dots (2.18)$$

式中, T_3 、 T_4 、 T_5 为阈值。同亮度差估计一样满足高斯分布, 取 95%置信区间求得相应阈值。在初始状态可以相对宽松给定初始各阈值, 之后逐步自动修正阈值。

(3)局部位置关系估计

通过亮度差估计与色度差估计后的疑似阴影点中仍然有前景物体存在, 本文阴影检测算法应用局部位置关系估计, 对二次疑似阴影区域划分后的点进行第三次阴影判别。对于属于二次阴影区域的像素点, 定义相邻间的像素点有如下位置关系:

$$\begin{cases} n(i,j,0) = n(i,j) \\ n(i,j,1) = n(i,j-1) \\ n(i,j,2) = n(i+1,j) \dots\dots\dots (2.19) \\ n(i,j,3) = n(i,j+1) \\ n(i,j,4) = n(i-1,j) \end{cases}$$

以点 $n(i,j,0)$ 作为种子点, 当 $n(i,j,0)=0$, 按图像逐行扫描顺序搜索下个点; 当 $n(i,j,0)=1$ 作为种子点。对种子点进行四邻域法扫描如图 2.13, 搜索连通区域, 直到无法继续连通为止。如果此连通区域全部被已知前景区域包围, 确定此连同区域为前景像素点, 其余为阴影点。




图 2.13 种子像素点与相邻像素点

本算法通过亮度差估计、色度差估计、局部位置关系估计依次判断疑似阴影像素点，检测得到阴影区域，对阴影剔除，以此获得良好的行人目标图像。

2.5 实验结果分析


本节采用在不同路段拍摄的行人过街视频对本章所研究的背景初始化、改进的 kalman 背景更新算法、行人提取以及阴影去除算法与其他算法效果对比，进行验证，并对算法性能进行分析。

2.5.1 背景初始化实验效果

本文采用不同场景下视频序列进行背景初始化，分别应用本文 2.2.1 提及的背景初始化算法实现，为了评价本文基于平滑序列方法的性能，与其他算法效果作对比，效果图如图 2.14 所示。



(1-a) 视频序列中某帧图像



(1-b) 平均值法获得图像



(1-c) 灰度直方图法获得图像



(1-d) 本文算法获得图像




图 2.14 不同背景初始化方法效果图对比

图 1、2 分别为不同场景。a 视频某帧图像，b 平均值法，c 灰度直方图法，d 本文算法。

2.5.2 改进的卡尔曼背景更新实验效果

图 2.15 是本文改进的卡尔曼背景更新算法效果图，(a) 与 (c) 为不同的连续视频序列中原始图像的灰度图。(b) 与 (d) 为对应当前帧的背景图像。由此可见，在行人数量较多的时刻背景更新性能依然良好。




图 2.15 本文改进的卡尔曼背景更新算法效果图

2.5.3 行人提取实验效果

在背景更新之后，由 2.3.1 小节中更新阈值 t_1 、 t_2 作为提取行人目标的阈值。对比传统固定阈值下前景提取方法，本文算法优点主要表现在，能够提取与背景灰度值相近的行人目标像素点，行人提取的更加完整。但同时也会将部分阴影融入到前景图像中，去除阴影问题将会在后文实验中进行。本文行人提取实验效果如图 2.16 所示。

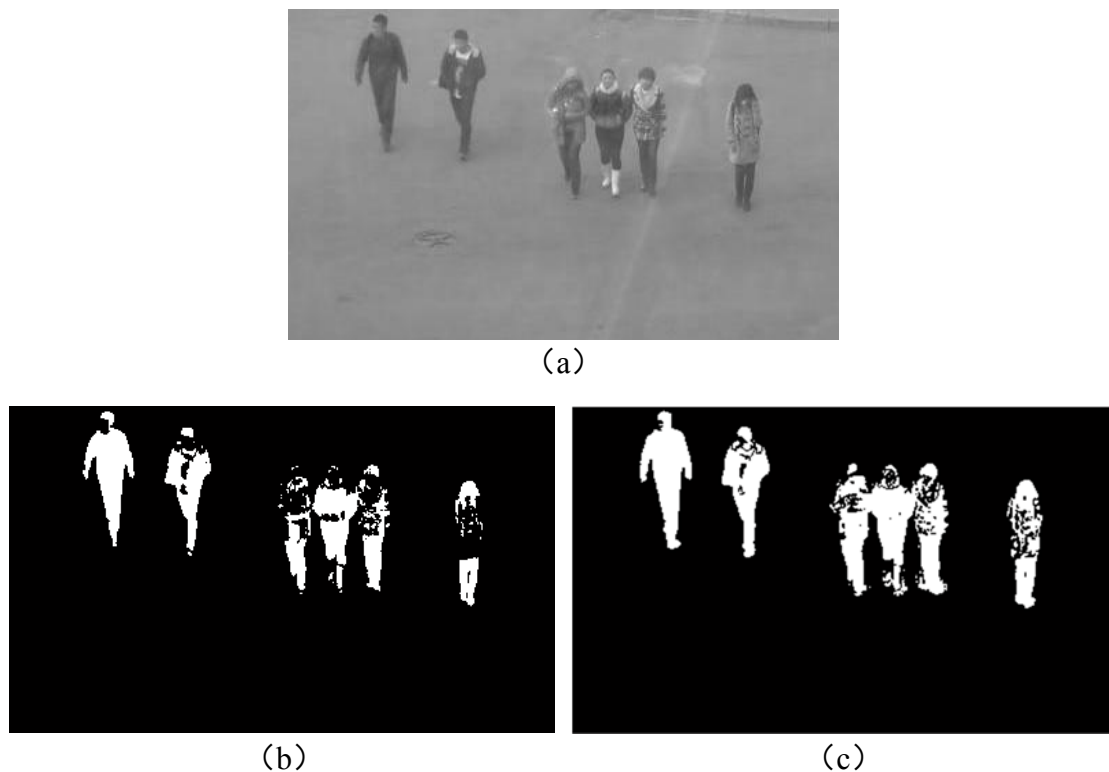


图 2.16 前景区域行人提取效果图

图 (a) 为视频源灰度图像，(b) 固定阈值下提取行人二值图像，(c) 本文自适应阈值下提取行人二值图像。

2.5.4 阴影剔除实验效果

本文采用视频帧序列对 2.4 节三步阴影判别算法编程实现，算法能够有效地去除阴影图像，替换为背景更新图像。实验效果如图 2.17 所示。





(c) 阴影检测图像

(d) 阴影去除图像

图 2.17 阴影剔除实验效果图

2.6 小结

本章节对行人检测算法进行了深入的研究与阐述。通过对比传统经典算法，本文提出了双阈值与强制背景更新这两个概念，改进了自适应背景更新算法，使自适应背景模型更加完善，能够应对复杂的环境变化，更趋于实用性。然后，根据背景模型的建立，在双阈值区间差分得到行人目标。最后，在行人目标基础上进行三步阴影判别算法去除阴影。本章节算法均通过算法流程图编程实现，最终获得较好的行人目标图像，实验验证算法有效性，同时为本文后续章节高层算法提供技术支持。

第3章 行人过街数量检测算法

行人数量检测是行人过街信号自适应优化系统的重要组成部分，因此，本章节也是本文的技术重点。从应用角度分析，在我国有关待过街行人数量检测算法的研究较少，其能够计算行人流量、人群密度，还能为行人过街配时提供数据支持，具有很好的应用前景。从技术角度分析，基于视频的行人过街数量检测算法依赖于精确的前景目标，是行人过街信号自适应优化的前提，因此，本章节研究内容是基于行人检测算法之上建立的。本章针对行人目标区域对图像进行分块处理，并提取像素与纹理特征，然后根据行人密度适时地选择特征表达，最后由经训练的 SVR 分类器模型进行预测，得到行人过街数量。通过实验验证以及对比分析数据，证明本文算法性能较好。




图 3.1 行人过街数量检测算法框架图

3.1 像素点数量统计特征

针对行人过街数量检测算法，国外学者已经进行了大量的相关工作，目前主

要分为基于像素点数量统计的方法^{[44][45]}、基于单种或多种纹理特征的方法^[46]、基于模板匹配的方法。

在基于像素点数量统计方法中，像素作为数字图像的基本组成单元，包含着图像全部的原色素与亮度信息，也是构成其他特征的基本元素。在实时监控的视频帧序列中，随着行人过街检测区域里行人数量的增加，行人目标所占图像的比例就越大，即前景像素点数量增多；反之，随着行人过街检测区域里行人数量的减小，前景目标所占图像的比例就越小，即前景像素点数量减少。基于像素点数量统计方法逻辑简单，特征易于提取，计算机处理速度快。同时，该方法能够应对外界环境条件变化，例如受光照变化影响很小。因此，基于像素点数量统计方法对行人过街数量检测有着较高的可靠性与实用性。上世纪 90 年代中期，学者 Velastin^[47]首次应用基于像素点数量统计方法进行人群密度估计。主要思想是背景差分之后的灰度图像，经过行人检测阈值处理得到二值化图像，然后统计前景目标像素点总和与当前图像的人群数量，最后收集大量图像数据，拟合出前景像素点数量与人群数量之间的函数关系，其中光学流与边缘检测算法进行了辅助处理。Velastin 等人为行人检测技术的快速发展奠定了基础，加快了视频监控下人群密度估计由理论研究到实际应用步伐。在此之后，有很多改进算法同样基于像素点数量统计，并结合多种边缘检测算法以消除人群遮挡的问题。但仍然主要围绕像素点数量统计方法进行人群密度估计和人群计数。

考虑到像素点数量统计特征具有鲁棒性好、准确度高和实时性好的特点。本文应用基于像素点数量统计方法作为行人数量检测算法之一。第二章中改进的自适应背景模型相比传统背景模型能够获得更好的行人目标，这也保证了提取较好的像素特征。

但由于像素点数量统计特征不能避免行人因互相遮挡产生的计数误差与行人在图像中的“近大远小”特点造成比例失调的问题，本文在后续小节中针对性的提出解决方法。

3.2 纹理特征

近年来，随着图像处理技术的深入研究，纹理特征描述图像的方法逐渐受到广泛关注。本文中行人在前景中的纹理明显不同于背景地面的纹理。行人与行人之间的共性以及行人与地面间的差异共同构成了行人特有的纹理特征。本文应用纹理特征中具有代表性的灰度共生矩阵对部分特定条件下的行人样本进行特征提取与表达。

3.2.1 纹理的定义

目前还没有权威和明确的定义表达什么是纹理，通常说纹理图像是一般具有结构单一、重复性强，类似于皮革、墙纸、布料等的一类图像。图像整体呈现出较强的周期性与规律性，但是在局部不一定具有这种性质。纹理反映的是灰度分布的统计量，图像的宏观表面特征。

3.2.2 纹理分析方法

纹理分析的是景物在整幅图像或者图像感兴趣区域的宏观特性。与 3.1 节基于像素点特征不同，纹理特征在图像一定范围内按照统一制定的规则对像素点灰度值计算，获得相应统计结果。在提取行人目标的纹理特征时，该图像或区域的特征辨识度更高，可以避免行人遮挡和人群数量较大时计数不准确的问题，并且对光照的变化有很好的适应能力。同时该特征具有旋转不变性，对噪声有一定的过滤作用。但是不同于颜色特征，纹理仅能反映景物的表面特性，并不能全部表达景物的本质属性，只通过纹理特征不能够获取信息更加丰富的二次图像特征。

由于纹理是根据灰度规律变化统计得来的特征，当检测图像的分辨率变化时，纹理会有很大变化。常用的纹理特征提取与匹配方法有如下三种：

(1) 统计法

灰度共生矩阵特征分析方法^{[48][49]}又称 Grey-level co-occurrence matrix，是统计法中最具代表性的一种算法，它在灰度共生矩阵自身特征基础上，得到二次图像特征，该特征的提取与匹配与 14 种参数有关，其中最能体现特征提取与匹配效果的是对比度、相关性、能量和同质性 4 个参数。另一种经典方法是局部二值模式又称 Local Binary Pattern，用来描述图像局部纹理特征。LBP 描述算子在固定窗口计算出特征向量。其难点在于如何优化特征向量维数，在不丢失信息情况下，尽量减少计算复杂度。

(2) 几何法

几何法是建立在图像纹理基元的一种纹理分析方法。通常认为任何复杂的纹理图形都是由简单的纹理基元以某种规律性的排列组成的。其中，较常用的方法有小波变换和 Gabor 滤波器进行图像纹理特征提取与匹配。但较难应对因行人遮挡产生的纹理提取与表达。

(3) 模型法

顾名思义，是在图像的构造模型基础上，以模型参数作为纹理特征。研究的主要方法是随机场模型法，其中包括著名的马尔可夫模型和吉布斯模型以及滑动平均模型等。由于模型方法不能通过多尺度方式表达特征，因此限制了表达行人特征的应用。

基于统计法的灰度共生矩阵从 41 年前开创性的提出以来，经过学者多年的不断地完善与改进，已经应用于众多领域。本文灰度共生矩阵以及相应衍生二次特征用于对行人特征提取与模式匹配。其纹理特征提取向量能够有效应对行人互相遮挡这类问题，在行人数量较多时有着较好的特征分类效果。本文将对灰度共生矩阵方法以及相关算法进行介绍。

3.2.3 灰度共生矩阵及其统计特征

灰度共生矩阵是一种有效的统计图像分析方法，被定义为像素点之间二维矩阵的

联合概率，表达了距离为 d ，角度为 θ 的一组像素对灰度出现频率。由此可见，灰度共生矩阵是对称矩阵，其阶数是共生矩阵的灰度级 N_n ，由 GLCM 可推出 14 种二次纹理特征。

假设 $F(x,y)$ 为当前帧灰度图，图像大小为 $W \times H$ ，灰度级别为 N_n ，则满足距离和方向函数关系的灰度共生矩阵为：

$$P(i,j) = \#\{(x_1, y_1), (x_2, y_2) \in W \times H \mid F(x_1, y_1) = i, F(x_2, y_2) = j\} \dots\dots (3.1)$$

式中， $\#(z)$ 为集合 z 中所有元素个数； P 为 $N_n \times N_n$ 的方阵； i, j 分别为原始灰度图像像素对 $F(x_1, y_1)$ 与 $F(x_2, y_2)$ 灰度值。如果 $F(x_1, y_1)$ 与 $F(x_2, y_2)$ 的像素距离为 d ，坐标横轴夹角为 θ ，则满足空间关系的 GLCM 为 $P(i,j,d,\theta)$ 。

为了避免存储数据溢出，对共生矩阵进行归一化处理，标准化如下：

$$p(i,j,d,\theta) = \frac{P(i,j,d,\theta)}{Sp} \dots\dots\dots (3.2)$$

式中， $P(i,j,d,\theta)$ 为灰度共生矩阵； Sp 为当前帧图像像素点总和。

由于原始图像灰度级为 256 级，对应灰度共生矩阵图像分辨率为 256×256 ，归一化后的特征向量高达 65536 维。虽然 GLCM 提取的纹理信息有较好的辨识能力，但是处理庞大的数据量耗时较长，加上计算统计二次特征量耗时会更长，算法远不能达到对实时性的要求。一般认为，在不丢失纹理特征信息的情况下，GLCM 阶数 N_n 越小，其特征向量维数就少，计算量也随之减小。通常将 256 灰度级缩减到 8 个灰度级，但缩减的规则并非平均压缩灰度级，而是对概率的量化，以求最接近原始灰度图像，并克服光照的影响。灰度级缩减后既保证纹理特征信息鉴别能力，又最大程度上减少计算量，提高了算法运算速度。下图以像素对距离为 $d=1$ ，横轴坐标夹角为 $\theta=0^\circ$ 的 8 级灰度 GLCM 矩阵为例，计算方法如图 3.2 所示。显而易见，灰度图像中像素值为 7、8 的像素对共出现三次，将原图像素对第一个数值作为共生矩阵横坐标位置，第二个数值作为共生矩阵纵坐标位置，像素对出现次数作为共生矩阵元素值。同理，得到如下共生矩阵。




图 3.2 生成 GLCM 图

灰度共生矩阵是原图像素对位置和角度的函数，反映了图像灰度变化幅度、速度与方向的综合信息，所以像素对间的步长和角度关系直接决定灰度共生矩阵的构成，需要对像素对组成分别考虑。

(一)距离选取：同幅图像提取的像素对的距离不同会得到不同的共生矩阵。像素对步长取值越小，则相邻像素之间关系越紧密，反应灰度的变化更加明显，计算出灰度共生矩阵的信息量就越大，因此本文算法中像素对距离 d 取值为 1。

(二)角度选取：同幅图像提取的像素对的横轴坐标角度不同会得到不同的共生矩阵。以一个像素为中心点，另一像素与其横坐标有 8 个角度，每呈 180° 两组像素对一样，共有四种角度互不重复，即 θ 取 0° 、 45° 、 90° 、 135° 。结合像素对步长 $d=1$ ，一共有四个方向的灰度共生矩阵生成，角度选取方法如图 3.3 所示。




图 3.3 GLCM 角度选取图

灰度共生矩阵仅仅反映了图像的表面性质，是纹理特征量分析的基础，通常不直接应用灰度共生矩阵作为特征量参与分类计算，需要进一步提取二次特征量以提高特征鉴别能力。

Haralick 从灰度共生矩阵纹理分析法中定义了 14 种特征统计量，然而这些特征间多数具有高度相关性，本文从这 14 种特征统计量中选择对比度、相关性、能量和同质性四个不相关特征作为灰度共生矩阵的二次特征统计量。下面将对这四种统计量详细描述：

(1)对比度

$$Con = \sum_{i,j} |i-j|^2 p(i,j,d,\theta) \dots\dots\dots (3.3)$$

对比度是一类可以较好描述图像纹理的特征，又称作惯性矩阵。从公式定义上理解， $|i-j|^2$ 是原图像像素对灰度差的平方，灰度相差越大该值越大， $P(i,j,d,\theta)$ 为当前像素对出现的次数，在图像范围内，其乘积之和就是对比度。对比度较大，说明偏离灰度共生矩阵对角线的元素值很大，则原图像灰度变化明显，相应的在视觉上图像纹路愈加清晰；对比度较小，说明偏离灰度共生矩阵对角线的元素值很小，则原图像灰度变化微弱，相应的在视觉上图像纹路愈加模糊。

(2)角二阶矩阵

$$ASM = \sum_{i,j} p(i,j,d,\theta)^2 \dots\dots\dots (3.4)$$

角二阶矩阵又称作能量，从公式定义上理解，是灰度共生矩阵中各个元素值的平方和。描述了图像纹理变化的复杂程度，如果图像纹路变化不明显， ASM 值就很小；如果图像纹路呈规律性变化， ASM 值就很大。本文中，当检测待行人过街区域前景行人数量相对较少时，虽然少数图像纹路变化明显，但是复杂变化的纹路较少，导致 ASM 值偏小；当检测待行人过街区域前景行人数量相对较多时，更多的图像纹路发生较大变化，导致 ASM 值偏大。可见， ASM 作为二次特征统计量能够有效判断前景图像行人数量变化程度。

(3)同质性

$$H = \sum_{i,j} \frac{p(i,j,d,\theta)}{1+|i-j|^2} \dots\dots\dots (3.5)$$

同质性又称逆差矩，由公式可知，图像像素对中两个元素灰度变化越小， H 越大；元素灰度变化越大， H 相应越小。同质性表示图像局部纹理的均匀程度，同质性越大代表区域内图像越平滑有序；相反的，同质性越小代表区域内图像凌乱无序。例如前景行人较多产生遮挡情况，遮挡临界边缘的 H 明显小于其他前景区域的 H 。同质性为处理行人遮挡判别提供特征依据。

(4)自相关性

$$Cor = \frac{\sum_{i,j} ijp(i,j,d,\theta) - \mu_x\mu_y}{\sigma_x\sigma_y} \dots\dots\dots (3.6)$$

式中， $\mu_x, \mu_y, \sigma_x, \sigma_y$ 表示为：

$$\mu_x = \sum_i i \sum_j p(i,j,d,\theta) \dots\dots\dots (3.7)$$

$$\mu_y = \sum_j j \sum_i p(i,j,d,\theta) \dots\dots\dots (3.8)$$

$$\sigma_x^2 = \sum_i (i - \mu_x)^2 \sum_j p(i,j,d,\theta) \dots\dots\dots (3.9)$$

$$\sigma_y^2 = \sum_j (j - \mu_y)^2 \sum_i p(i,j,d,\theta) \dots\dots\dots (3.10)$$

自相关性对图像纹理一致性进行判断，反映灰度共生矩阵横向或纵向元素的相似性。当矩阵横向坐标元素相似性大时，代表水平方向纹路较明显，该方向的 Cor 值大于其他方向 Cor 值；同理，当矩阵纵向坐标元素相似性大时，代表竖直向纹路较明显，该方向的 Cor 值大于其他方向 Cor 值。

3.2.4 LBP 特征

纹理特征经典代表之一的 LBP (Local Binary Patterns) 又称局部二值模式, 最早由 T. Ojala^{[50][51]}等人提出用来描述图像局部纹理变化, 由于算法原理的固有特点, 使其具有较好的旋转不变性, 最重要的是 LBP 能够克服因光照对行人灰度变化产生的负面影响, 并提取出有效的行人特征。本章中, 本文算法与应用 LBP 算子的行人计数算法进行实验对比评价。

局部二值模式在图像中以 3*3 区域为单元, 区域中心为原点, 原点周围 8 邻域像素点按事先规定顺序分别与原点像素灰度值比较, 若邻域像素点值小于原点像素灰度值, 该邻域像素值置 0; 若邻域像素点值大于原点像素灰度值, 该邻域像素值置 1。由此 8 邻域得到的八位 01 代码就是 LBP 特征表达值。如图 3.4 所示。




图 3.4 生成 LBP 特征图

定义公式如下:

$$L(x_o, y_o) = \sum_{n=0}^{l-1} 2^n m(i_n - i_o) \dots\dots\dots (3.11)$$

$$m(k) = \begin{cases} 1, & \text{if } k > 0 \\ 0, & \text{else} \end{cases} \dots\dots\dots (3.12)$$

式中, L 为 LBP 特征值; (x_o, y_o) 为原点像素; l 为邻域次序; i_l 为邻域像素灰度; i_o 为原点像素灰度; $m(k)$ 为判断条件。

再通过统计 LBP 特征值的直方图, 得到完备的特征向量进行特征表达。又如之后出现的圆形 LBP 以及均匀 LBP 都是在原有的局部二值模式基础上改进而来。

3.3 特征优选及图像分块

在计算行人过街数量之前, 需要根据特征属性不同以及应用条件的差异选择合适的行人检测特征。行人密度判别能够以最少的计算量、最短的耗时为代价对行人数量进行预先模糊判断, 选择合适的行人检测特征用于分类器训练学习有助于提高本文行人过街数量检测算法的准确率。

3.3.1 行人密度判别

本文行人数量检测方法特征提取融合了基于像素统计特征和纹理特征中的灰度共生矩阵以及由此得到的二次统计特征，为了达到行人过街数量有效计数的目的，需要根据各种特征属性的不同，提取合适的特征向量利用分类器训练学习。基于像素点数量统计这一特征在行人过街数量较少并且遮挡情况不严重时，特征提取效果较好；基于纹理特征在行人过街数量较多时，能够克服因行人互相遮挡造成计数不准的弊端，容许大多数这类问题产生的误差。在实际调查视频监控行人过街区域中发现，视频设备均处于距地面 8 米以上高度且相对俯视角度，考虑到行人个体之间“斥力”因素的影响，认为行人过街数量较少时，行人之间不会产生明显遮挡现象。本文通过对前景像素点总数所占当前图像像素点总数比例设定阈值粗略估计行人密度。当该比例小于阈值时，认为前景行人数量较少，选择像素点特征；当该比例大于阈值时，认为前景行人数量较多，选择纹理特征。以上整个过程就是行人密度判别的主要部分，亦是特征优选方法。

为了确定特征优选阈值，本文从行人样本集中手动选择了行人无遮挡和有遮挡各 100 幅图像，分别统计这两种情况下行人目标所占图像比例。如图 3.5 所示，横坐标为图像数，纵坐标为行人占该幅图像百分比。红色星形为行人无遮挡发生时，蓝色圆圈为行人有遮挡发生时。根据两种情况的差异，利用 2.2.2 节大津算法思想，行人所占图像比例以阈值 $T_{front}=10\%$ 为界限。图中绿色横线为判断行人密度阈值。




图 3.5 行人密度判别图

实际监控下，行人密度判别阈值的设定是在初始化中完成的，初始化共实验 10 次取平均时间 1.5691s，行人过街数量计算时只需根据阈值进行特征优选，实验共计 5 万帧视频中平均每帧图像用于行人密度判断耗时为 17ms。

3.3.2 图像分块方法

由于监控摄像机拍摄行人过街区域范围广，会造成一定的“透视”现象，产生“近大远小”的效果，在监控视频读取每帧图像中，距离摄像机近的行人所占像素点数量多，距离摄像机远的行人所占像素点数量少。“透视”现象对计算基于像素点特征分析方法的行人数量造成很大误差，仅仅采用像素点数量统计不能获得准确行人过街数量。本文通过对提取不同特征的图像分别进行图像分块处理，减少误差的同时提高计算精度。具体图像分块依据在本章实验效果分析一节有详细介绍。

(1) 基于像素点数量统计特征分块方法

应用图像分块处理使像素点数量统计融入了位置信息，通过该特征构成的多维特征向量中包含了像素点数量与对应位置关系，再经过 SVR 的训练学习，可以得到准确的行人过街数量。其中图像分块多少决定了特征向量维数大小。通过实验发现，随着图像分块数的增多“透视”现象的干扰减小，但是特征向量的维数也随之增大，这以计算耗时更长为代价，并且需要更多的训练样本来学习。本文兼顾特征提取辨识度与计算效率，通过实验数据结果观察，采用 4×8 分块模式像素点特征鉴别能力最强，分块效果图如下。



图 3.6 像素特征分块效果

(2) 基于纹理特征分块方法

纹理特征分块具有像素点特征分块的优缺点之外，根据纹理的性质分析，不同的分块模式对结果影响很大。GLCM 的二次统计特征角二阶矩阵是全局统计特征，图像分割边缘的不确定性，破坏纹理整体结构，导致该类统计特征统计精度降低或失效。而同质性与角二阶矩阵不同，同质性表达图像的局部统计特征，如果图像分块过大，纹理的局部性质变得模糊粗糙，难以通过同质性正确回答特征统计量。

确定图像子区域大小的方法是矛盾的，若分块区域较大，纹路的周期性、规律性得以保留，图像识别率较高，但局部纹理性质变得含糊不清；若分块区域较小，图像分割精度提高，但纹理信息提取不完整，丢失部分纹理特征，图像识别率有所降低。综上所述，本文在纹理特征提取中对图像进行 4×5 分块模式操作，效果图如下。



图 3.7 纹理特征分块效果

3.4 基于 SVM 的行人计数算法

在不同行人密度下，分别进行特征提取得到的特征向量隐含了每帧图像的全部统计信息，需要通过分类器的自主学习机制对样本特征量训练分类，统计决策训练学习有效的分类模型，具备固定场景下统一的分类标准，即该模型能够实用于预测行人过街数量。

3.4.1 SVM 工作原理

在本文研究的行人计数问题上，实际行人过街等待区域人数变化不定，并且不同时刻人群数量相差很大，这对分类器的性能有苛刻要求，目前分类器依照模型不同主要有贝叶斯分类器、神经网络分类器、SVM^[52-56]等。本章中，分类器以预测未知图像中行人数量为机理，采用分类方式的机器学习方法不能满足几十种人数分类的目的。考虑到分类器要具备自主学习机制预测行人数量，而非对人群密度进行等级分类，例如高、中、低密度划分。本章采用 SVM 下的支持向量回归(SVR)方法进行行人数量预测，下面根据 SVM（支持向量机）原理介绍分类模型计算方法。

SVM 最早是由 Vapnik 作为二分类寻优算法而提出，之后逐渐发展用于多分类和数据回归等方法。SVM 的核心思想是核函数，能够将低维空间非线性不可分割的向量映射到高维空间，在高维空间不可分割的特征向量变得线性可分，而后通过已知训练数据和训练标签寻找最优超平面建立判别函数。虽然在三维以上的高维空间中最优超平

面不利于坐标表达和观察，但却是实际存在的。

3.4.1.1 非线性分类算法

(1) C-SVC

非线性分类算法，将低维空间无法正确分类的训练集数据映射到高维空间，在高维空间中原有的训练集数据变得线性可分。但多数情况下无法保证将数据映射到满足线性可分的维数，所以，同线性不可分的二分类算法原理，引入了松弛变量 ξ_i 放宽最优超平面约束条件，通过惩罚参数 C 限定 ξ_i 取值，最终确保目标函数获得最优解。样本数据在低维空间到高维空间的映射关系为：

$$\tilde{f} = \{(\tilde{x}_1, y_1), \dots, (\tilde{x}_l, y_l)\} \dots\dots\dots (3.13)$$

式中， $\tilde{x}_i = \phi(x_i)$ 。分类面为：

$$(\tilde{k} \cdot \tilde{x}) + \tilde{b} = 0 \dots\dots\dots (3.14)$$

最优超平面表示为：

$$\min_{k, b, \xi} \frac{1}{2} \|\tilde{k}\|^2 + C \sum_{i=1}^l \xi_i \dots\dots\dots (3.15)$$

其约束条件为：

$$y_i((\tilde{k} \cdot \tilde{x}_i) + \tilde{b}) \geq 1 - \xi_i, i = 1, \dots, l \dots\dots\dots (3.16)$$

综上，归结到对偶理论表达式为：

$$\begin{cases} \min_{\alpha} \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j \alpha_i \alpha_j (\phi(x_i) \cdot \phi(x_j)) - \sum_{j=1}^l \alpha_j \\ \sum_{i=1}^l y_i \alpha_i = 0, 0 \leq \alpha_i \leq C \end{cases} \dots\dots\dots (3.17)$$

式中， $\phi(x_i) \cdot \phi(x_j)$ 在高维空间中计算量异常庞大，因此引入一种在高维空间里直接计算特征向量内积的方法，称为核函数。核函数能够将高维空间复杂的计算量压缩到低维空间原计算量的数量级。核函数表示为：

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j) \dots\dots\dots (3.18)$$

所以，式 (3.17) 可以表示为：

$$\begin{cases} \min_{\alpha} \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j \alpha_i \alpha_j K(x_i \cdot x_j) - \sum_{j=1}^l \alpha_j \\ \sum_{i=1}^l y_i \alpha_i = 0, 0 \leq \alpha_i \leq C \end{cases} \dots\dots\dots (3.19)$$

有：

$$b^* = y_j - \sum_{i=1}^l y_i \alpha_i^* (x_i \cdot x_j) \dots\dots\dots (3.20)$$

最终决策函数表达式为:

$$\text{sgn}\left(\sum_{i=1}^l y_i \alpha_i^* K(x_i, x_j) + b^*\right) \dots\dots\dots (3.21)$$

目前, C-SVC 分类器能够适用于复杂的分类要求, 也是较为常用的分类算法之一。

(2) v-SVC

v-SVC 取代 C-SVC 的惩罚参数 C , 引入了新的参数 v , 用来控制训练数据的分类间隔和训练误差。其变化区间为 $v \in (0, 1]$ 较小时, 偏向控制数据分类最大化; 当 v 取值较大时, 偏向控制训练误差最小化。其最优超平面为:

$$\min_{k, b, \xi, \rho} \frac{1}{2} \|\tilde{k}\|^2 - v\rho + \frac{1}{l} \sum_{i=1}^l \xi_i \dots\dots\dots (3.22)$$

约束条件为:

$$\begin{cases} y_i((\tilde{k} \cdot \tilde{x}_i) + \tilde{b}) \geq \rho - \xi_i \\ \xi_i \geq 0, i = 1, \dots, l \\ \rho \geq 0 \end{cases} \dots\dots\dots (3.23)$$

综上, 归结到对偶理论表达式为:

$$\begin{cases} \min_{\alpha} \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j \alpha_i \alpha_j K(x_i \cdot x_j) \\ \sum_{i=1}^l y_i \alpha_i = 0, 0 \leq \alpha_i \leq \frac{1}{l}, \sum_{i=1}^l \alpha_i \geq v \end{cases} \dots\dots\dots (3.24)$$

最终决策函数表达式为:

$$\text{sgn}\left(\sum_{i=1}^l y_i \alpha_i^* K(x_i, x) + b^*\right) \dots\dots\dots (3.25)$$

在非线性分类算法中, C-SVC 与 v-SVC 原理不同, 但分类效果较为相似。通常实验中, 根据不同样本条件与功能要求分别调试两种算法。

3.4.1.2 回归分析算法

SVM 能够处理分类问题之外, 衍生的另一个强大功能是能够作为数据回归预测使用。虽然 SVC 与 SVR 实现的目的都是寻找高维空间的最优超平面, 不同的是, SVC 寻找的是在最大限度上区分已有类别的分类平面, 表现在样本标签 label 涵盖了测试集所有的分类结果, 一般为整数。而 SVR 则寻找能够有效预测数据的平面, 预测结果作为回归数值在相对应样本标签值附近波动, 预测结果一般为小数。本文行人过街计数方法就是基于 SVR 的回归分析算法实现的, 下面介绍最常用的两种支持向量回归算

法。

(1) ε -SVR

根据回归算法属性分析，预测结果不一定落在训练样本标签值上，预测值将会相对真实值有些偏差，偏差的距离用参数 ε 表示， $\varepsilon \geq 0$ 。同分类方法一致，设欲求取的平面满足如下公式：

$$f(x) = k \cdot x + b, \quad k \in R^d, b \in R \dots\dots\dots (3.26)$$

若满足真实值与预测值的差的绝对值 ε 很小，则公式中的 k 就是要求取的平面。也就是求：

$$\min_{k,b} \frac{1}{2} \|k\|^2 \dots\dots\dots (3.27)$$

对应的约束条件为：

$$\|y_i - (k \cdot x_i + b)\| \leq \varepsilon \dots\dots\dots (3.28)$$

理想情况下都能满足上式条件。有时，由于样本集数据与标签对应模糊的问题和系统误差的干扰，使得该超平面难以呈现。这时需要适当放宽约束，容纳个别落在 ε 之外的点。因此，引入参数松弛变量 C 改变目标函数判别规则。则式 (3.27)、(3.28) 可改写为：

$$\begin{aligned} \min_{k,b,\xi,\xi^*} \quad & \frac{1}{2} \|k\|^2 + C \sum_{i=1}^l (\xi_i + \xi_i^*) \\ \text{s.t.} \quad & \begin{cases} \xi_i, \xi_i^* \geq 0, i=1, \dots, l \\ y_i - k \cdot x_i - b \leq \varepsilon + \xi_i^* \\ k \cdot x_i + b - y_i \leq \varepsilon + \xi_i \end{cases} \dots\dots\dots (3.29) \end{aligned}$$

式中， $s.t.$ 为约束条件； y_i 为回归分析预测值。

综上，归结到对偶理论，应用拉格朗日变换得：

$$\begin{aligned} \min_{\alpha, \alpha^*} \quad & \frac{1}{2} (\alpha - \alpha^*)^T (\alpha - \alpha^*) K(x_i, x_j) + \varepsilon \sum_{i=1}^l (\alpha_i + \alpha_i^*) + \sum_{i=1}^l y_i (\alpha_i - \alpha_i^*) \\ \text{s.t.} \quad & \sum_{i=1}^l (\alpha_i - \alpha_i^*) = 0, 0 \leq \alpha_i, \alpha_i^* \leq C, i=1, \dots, l \end{aligned} \dots\dots\dots (3.30)$$

回归公式为：

$$\sum_{i=1}^l (-\alpha_i + \alpha_i^*) K(x_i, x) + b \dots\dots\dots (3.31)$$

(2) ν -SVR

作为数据回归分析算法之一， ν -支持向量回归引入了参数 ν 来控制支持向量个数，与 ν -SVC 相似，目的是改变数据分类间隔。但是与非线性分类算法中 ν 代替了松弛变量 C 这一点不同的是，这里的 ν 代替了 3.4.1.2 (1) 中 ε -SVR 的 ε 。引入参数 ν 后，求

最优值以及约束条件公式应为：

$$\begin{aligned} \min_{k, b, \xi, \xi^*, \varepsilon} \quad & \frac{1}{2} \|k\|^2 + C(v\varepsilon + \frac{1}{l} \sum_{i=1}^l (\xi_i + \xi_i^*)) \\ \text{s.t.} \quad & \begin{cases} \xi_i, \xi_i^* \geq 0, i = 1, \dots, l \\ y_i - k \cdot x_i - b \leq \varepsilon + \xi_i^* \\ k \cdot x_i + b - y_i \leq \varepsilon + \xi_i \\ \varepsilon \geq 0 \end{cases} \end{aligned} \quad (3.32)$$

式中， $s.t.$ 为约束条件； y_i 为回归分析预测值。

综上，归结到对偶理论，应用拉格朗日变换得：

$$\begin{aligned} \min_{\alpha, \alpha^*} \quad & \frac{1}{2} (\alpha - \alpha^*)^T (\alpha - \alpha^*) K(x_i, x_j) + y^T (\alpha - \alpha^*) \\ \text{s.t.} \quad & \begin{cases} e^T (\alpha - \alpha^*) = 0, e^T (\alpha + \alpha^*) \leq Cv, \alpha_i \geq 0, \alpha_i^* \leq C/l, i = 1, \dots, l \end{cases} \end{aligned} \quad (3.33)$$

解得回归公式为：

$$\sum_{i=1}^l (-\alpha_i + \alpha_i^*) K(x_i, x) + b \quad (3.34)$$

由最终目标函数可见，两种回归分析算法一致，有着极高的相似性。

3.4.2 算法实现

由于实时监控所需，本文行人过街计数模型长期处于工作环境，这对模型的鲁棒性和实时性都有严格要求。

行人计数的过程是基于离线训练学习的 SVR-model 上实现的，训练集应该具有普适性，选择少的样本数量且涵盖当前场景下尽可能多的行人状态，这样不仅能够提高行人计数精度还能增强该场景下算法的鲁棒性。针对实时性方面，考虑到感兴趣区域内行人移动速度相对较慢，视频序列前后连续帧图像之间基本无变化，因此算法预先对视频等间隔提取图像，去除重复帧图像，很大程度上减少了计算量，以此满足实时性要求。

支持向量回归作为计算行人过街数量的核心部分，其模型的建立过程尤为重要。本文设计如图 3.8 所示的 SVR 实现过程。




图 3.8 SVR 实现过程图

需要注意的是，要对 3.1 节与 3.2 节提取的两种特征和二次统计特征进行数据归一化处理，使特征向量的元素取值范围在[0,1]之间，如果元素值过大，出现连乘运算会造成计算结果更加庞大，在硬件设备中出现数据溢出现象，导致模型失效。在训练样本中，分别为训练数据手动添加标签，带有标签的训练集作为构成该 SVR 模型的所有输入量，只需要在该监控场景下初始化情况应用。

关于训练 SVR 模型方面，选择合适的核函数至关重要，不同核函数参与运算，决定 SVR 模型中的不同目标函数构成，导致不同核函数条件下的预测人数也有较大差异，距离实际行人数量有不同程度偏差。目前，核函数主要有如下四种：

①线性核函数：

$$K(x_i, x_j) = x_i^T x_j \dots\dots\dots (3.35)$$

②多项式核函数：

$$K(x_i, y_j) = (\gamma x_i^T x_j + r)^d, \gamma > 0 \dots\dots\dots (3.36)$$

③RBF 核函数：

$$K(x_i, y_j) = \exp(-\gamma \|x_i - y_j\|^2), \gamma > 0 \dots\dots\dots (3.37)$$

④Sigmoid 核函数：

$$K(x_i, y_j) = \tanh(\gamma x_i^T y_j + r) \dots\dots\dots (3.38)$$

式中， r ， d ， γ 为核函数参数。

对于不同核函数，其共同点如 3.4.1 中所讲，能够将高维空间无法计算的庞大数据转换成向量内积形式便可计算。而不同核函数有不同的适应条件，相应的参数功能均有所差异。根据学者以往经验通常首选 RBF 核函数，本文与其他核函数进行对比分析。

参数寻优方面，训练支持向量回归模型之前，先要对相关参数进行优选，参数设定是影响模型性能的重要指标。通过训练集样本数据和样本标签的对照关系，在训练集内部进行自交叉验证(cross-validation)，目的是使不同标签下对应的样本数据之间差别

最大化, 类间区分越明显, 数据拟合识别正确率就会越高, 最后将得到的最优目标参数带入训练函数, 提高拟合效果。常用的交叉验证方法有 3 种: Hold-Out, K-fold Cross, Leave-One-Out Cross。本文应用 Leave-One-Out Cross Validation 简称(LOO-CV)进行参数寻优。LOO-CV 从训练集全部 M 个样本中每次抽取一个作为测试样本, 其余 $M-1$ 个作为训练子集。每个训练样本都做一次测试样本, 这样循环 M 次共有 M 组数据。所求相关参数在取值范围内遍历所有可能, 当各组测试分类正确率平局值最高时的参数值即为参数寻优结果, 该平均值作为 SVR 回归性能指标之一。LOO-CV 虽然较其他方法用时略长, 但却尽可能的充分利用了训练集数据, 取多次试验总和的平局值, 以便准确的反映模型性能, 并且寻优过程没有环境噪声干扰, 保证结果准确可靠, 较 Hold-Out 和 K-fold Cross 方法有更好的实验结果。交叉验证结果以均方误差(mean squared error)和平方相关系数(squared correlation coefficient)作为评价指标, 标准如下:

$$MSE = \frac{1}{l} \sum_{i=1}^{\bar{l}} (f(x_i) - y_i)^2 \dots\dots\dots (3.39)$$

$$r^2 = \frac{(\bar{l} \sum_{i=1}^{\bar{l}} f(x_i) y_i - \sum_{i=1}^{\bar{l}} f(x_i) \sum_{i=1}^{\bar{l}} y_i)^2}{(\bar{l} \sum_{i=1}^{\bar{l}} f(x_i)^2 - (\sum_{i=1}^{\bar{l}} f(x_i))^2)(\bar{l} \sum_{i=1}^{\bar{l}} y_i^2 - (\sum_{i=1}^{\bar{l}} y_i)^2)} \dots\dots\dots (3.40)$$

式中, MSE 为均方误差; r^2 为平方相关系数; $f(x)$ 为当前实际人数; y 为回归模型预测人数。

均方误差反映了样本自学习的平均误差水平, 取值越小越能够说明系统有效性高。平方相关系数取值越接近 1, 说明系统正确识别率越高。

实时计算行人数量方面, 通常标准监控视频的帧速率为 25fps/s, 本文对视频进行等帧数间隔提取, 每 5 帧提取 1 帧图像, 则 1 秒时间内有 5 帧待处理图像。通过行人计数算法分别预测 5 帧图像的人数, 再对预测结果取平均值:

$$ave = \frac{\sum_{i=1}^5 y_i}{5} \dots\dots\dots (3.41)$$

式中, i 为 1 秒内待处理帧数; y 为第 i 帧行人数量。

取平均值可以减小奇异值的干扰, 减少误检率的发生, 同时对预测人数平滑处理, 最终得到以秒为单位的实时行人数量。

3.5 实验效果分析

本小结对本章算法进行对比实验, 验证算法的有效性。实验在 CPU 为 Intel Core i5, 2.67GHz, 内存 3.5GB 的 PC 环境下开发测试, 采用 MATLAB 和 LIBSVM 工具包实现本文行人过街计数算法, 所用视频及图像均为 640*400 分辨率。

3.5.1 交叉验证实验效果

由于图像分块处理与核函数同时决定了交叉验证结果并且为后续构造 *SVR* 模型提供参数设定标准。本文采用控制变量法进行交叉验证，采用均方误差和平方相关系数作为算法性能的评价指标。训练样本为 1562 幅视频图像，标签人数最少 0 人，最多 36 人。

(1) 基于像素点特征

线性核函数不满足本文算法应用条件，而多项式核函数也更适合分类情况，且图像分块要求监控视频的高宽是分割块数的整数倍。表 3.1 与表 3.2 为选择不同图像分块数与核函数对系统性能的影响。

表 3.1 RBF 核函数下系统性能

图像块数	无	4×5	4×8	5×8	8×8
均方误差	1.98942	1.11153	0.43901	0.49321	0.51936
平方相关系数	0.948156	0.971008	0.988554	0.987135	0.986449

表 3.2 Sigmoid 核函数下系统性能

图像块数	无	4×5	4×8	5×8	8×8
均方误差	2.02236	1.48416	1.44926	1.41876	1.39203
平方相关系数	0.947346	0.961347	0.962254	0.963105	0.963879

对比表 3.1 与表 3.2 可知，本文单纯基于像素统计算法选择 RBF 核函数与图像分块模式为 4×8 时，均方误差为 0.43901，平方相关系数为 0.988554，算法交叉验证效果最好。图 3.9 为基于像素点特征交叉验证效果图。




图 3.9 基于像素点特征交叉验证效果图

(2) 基于纹理特征

在基于纹理特征交叉验证中，线性核函数和多项式核函数同样不适用本文算法。考虑 3.3.2 小节图像分割边界对纹理特征的影响，进行多组实验获得最佳分块模式。表 3.3 为选择不同图像分块数与核函数对系统性能的影响。

表 3.3 RBF 核函数下系统性能

图像块数	无	2×4	4×5	5×5	4×8
均方误差	1.52934	1.05152	0.435594	0.554779	0.651213
平方相关系数	0.960129	0.972574	0.988659	0.985604	0.98305

表 3.4 Sigmoid 核函数下系统性能

图像块数	无	2×4	4×5	5×5	4×8
均方误差	2.95555	2.48326	2.04537	2.06483	1.82660
平方相关系数	0.925113	0.935562	0.947173	0.947304	0.953072

对比表 3.3 与表 3.4 可知，本文单纯基于纹理特征算法选择 RBF 核函数且图像分块模式为 4×5 时，均方误差为 0.435594，平方相关系数为 0.988659，算法交叉验证效果最好。图 3.10 为基于纹理特征交叉验证效果图。




图 3.10 基于纹理特征交叉验证效果图

(3) 基于密度判别方法

本文密度判别的行人计数算法，并非提取混合特征训练学习，而是根据行人像素点数量自动选择特征提取方法。相对于单一特征的交叉验证准确度明显提升。图 3.11 与 3.12 分别为通过密度判别特征优选后的交叉验证效果。




图 3.11 基于密度判别的像素特征交叉验证效果




图 3.12 基于密度判别的纹理特征交叉验证效果

表 3.5 在核函数为 RBF，图像分块模式不变条件下对比了基于像素点特征、基于纹理特征与本文基于密度判别特征提取方法交叉验证效果。

表 3.5 不同特征表达下交叉验证对比

预处理	单一特征方法		本文基于密度判别方法	
特征表达	像素点特征	纹理特征	像素点特征	纹理特征
均方误差	0.439010	0.435594	0.158839	0.136665
平方相关系数	0.988554	0.988659	0.994188	0.992853

通过对比上表可知，本文基于密度判别方法的训练样本比提取任意单一特征的训练样本有更好的交叉验证效果，交叉验证结果作为训练 SVR 模型参数参与模型构造，交叉验证效果将间接地反映 SVR 模型的优劣。

3.5.2 行人过街计数实验效果

本文行人过街计数算法融入了行人密度判别模型，相对传统一般算法在行人计数精度上明显提高，通过对比像素点特征和 GLCM 特征以及 LBP 特征表达下的行人计数算法，以平均绝对误差 (MAE) 和平均绝对百分误差 (MAPE) 作为算法性能的评价指标，如公式 (3.42)、(3.43)。本文对同一场景不同时间进行两次测试，样本库包括 1562 帧训练样本和 775 帧、435 帧的预测样本，为了避免预测样本图像与训练样本图像过于接近而造成行人过街计数“高精度”的假象，因此本文所选预测样本与训练样本均源

自视频序列较大时间间隔的灰度图像，保证行人过街计数算法具有普适性。实验证明，本文行人过街技术检测精度在 90% 以上。评价指标见公式 (3.42)、(3.43)。

$$MAE = \frac{1}{n} \sum_{i=1}^n |N_p(i) - N_r(i)| \dots\dots\dots (3.42)$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{N_p(i) - N_r(i)}{N_r(i)} \right| \times 100\% \dots\dots\dots (3.43)$$

式 (3.42)、(3.43) 中， n 为预测图像的总数； $N_p(i)$ 为预测第 i 帧的行人数量； $N_r(i)$ 为第 i 帧的真实行人数量。本文行人过街计数效果见以下图表。




图 3.13 预测集 1 行人过街数量




图 3.14 预测集 2 行人过街数量

本文以绝对误差作为评价指标与基于像素点特征、基于 GLCM 特征和局部二值模式 (LBP) 的行人过街计数算法效果进行对比。通过图 3.15 及 3.16 可见，本文算法在两组预测集中过街行人计数绝对误差较小，优于其他算法。




图 3.15 预测集 1 过街行人绝对误差对比图

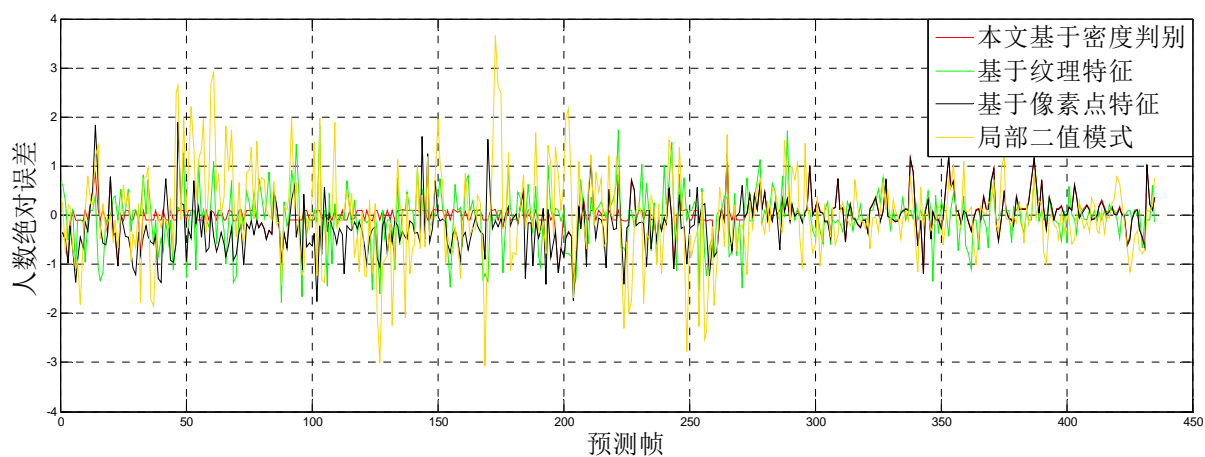


图 3.16 预测集 2 过街行人绝对误差对比图

表 3.6 行人过街数量检测算法性能评价 1

过街行人计数算法	预测集 1					
	MAE	MAPE	平均 耗时	最少 人数	最多 人数	平均 人数
基于像素点特征	0.40	14.49%	2×10^{-6} ms	0	14	4.01
基于 GLCM 特征	0.43	14.60%	175ms			
本文基于密度判别	0.24	7.54%	183ms			
基于 LBP 特征	0.55	19.58%	67ms			

表 3.7 行人过街数量检测算法性能评价 2

过街行人计数算法	预测集 2					
	MAE	MAPE	平均 耗时	最少 人数	最多 人数	平均 人数
基于像素点特征	0.39	5.92%	2×10^{-6} ms	0	26	11.29
基于 GLCM 特征	0.37	5.52%	173ms			
本文基于密度判别	0.20	4.81%	187ms			
基于 LBP 特征	0.64	8.71%	65ms			

通过对比以上图表，本文算法虽耗时较多，是因密度判别部分占用了一定计算时间，而本文行人过街计数算法设计要求处理图像速度为 5fps/s 就能够保证实时检测行人数量，即每帧图像处理时间不大于 200ms，因此仍满足系统实时性要求。本文基于行人密度判别的过街行人计数算法具有较高精度，当行人数量较少时效果更为明显。得益于本文预先进行图像密度判别，能够选择适合的特征表达，在训练 SVR 模型与预测行人数量时输入的特征向量具有更高的类间辨识能力，决定了标函数拟合精度高，行人计数准确，满足不低于 90%检测精度的要求。

3.6 小结

本文首先统计前景行人像素点数量，给出预先判断行人密度方法，根据不同密度程度选择合适的行人特征提取，针对两种特征属性分别对图像进行相应分块模式操作。再通过交叉验证获得参数寻优结果，引入 SVR 训练模块得到高低密度下两种情况的行人过街计数模型，最终输出行人数量。最后，分析预测结果以及对比了不同行人计数算法的检测精度，证明本文行人过街计数算法具有较高的检测精度和实时性。

第4章 行人过街信号自适应优化方法

行人过街信号自适应优化方法是利用视频检测获取的实时待过街行人数量、行人数量与行人过街时间之间的关系以及行人过街信号优化相关影响因素，确定行人信号触发时间。该方法基于待过街行人数量，以保障行人过街安全为前提，以最高效充分利用过街时间为目的，通过检测路段的历史行人数量与过街时间数据为样本，引入支持向量回归学习机制，训练 SVR 模块，自动地实时预测未来行人穿越路段所需时间，能够为行人过街信号配时提供理论支持，避免行人过街时间不足或绿灯空放情况发生。

4.1 传统行人过街时间计算

行人过街时间模型^[57-59]中，行人绿灯的设置是为了满足行人过街时间需求。在一个信号周期内，尽可能保证在行人绿灯时间最短且行人全部通过人行横道，一旦出现绿灯空放或行人跨周期滞留的现象，必然导致行人延误产生。现有行人过街时间计算公式为：

$$T_p = \frac{N_{p\max}}{s_p d} + \frac{b}{v_p} + l = \frac{q_p C}{s_p d} + \frac{b}{v_p} + l \dots\dots\dots (4.1)$$

式中， T_p ——行人过街时间，s；

$N_{p\max}$ ——信号周期内过街行人量较大方向人数，p；

s_p ——绿灯时间行人饱和流率，p/s.m；

q_p ——行人到达率，p/s；

C ——信号周期，s；

d ——人行横道宽度，m；

b ——人行横道长度，m；

v_p ——行人步速，通常取 1.0~1.5m/s；

l ——行人损失时间，s。

行人过街平面图如图 4.1 所示。




图 4.1 平面结构图

其行人过街区域人数变化图如图 4.2 所示。




图 4.2 理想行人过街区域人数变化图

图中, t 为时间序列, n 为行人数量, t_g 为行人过街时间。从公式中可以看出, 行人过街时间是在理想情况下, 假定行人服从平均分布到达的前提下计算得到的, t_g 刚好满足行人全部过街且用时最短。

实际路段中, 受到附近公交车站和周围工作环境影响, 不同时段行人出行量相差较大, 高峰时段待过街行人数量较多, 所需过街时间多于平峰时较少过街行人所需的过街时间; 低峰时段待过街行人数量较少, 行人所需过街时间少于平峰时段过街时间。传统行人过街时间计算方法是假设在图 4.2 理想情况下应用的, 然而实际行人到达率并不服从指定分布, 导致计算过街时间结果与实际行人过街时间有偏差。因此, 造成误差的主要原因是, 传统行人过街时间计算方法不能自动适应每次行人过街时间需求。实际行人过街区域人数变化图如图 4.3 所示。




图 4.3 实际行人过街区域人数变化图

图中, t_g 为传统计算方法得出的行人过街时间。

误差 Ea 表达式:

$$Ea = \begin{cases} t_g - t_i, & \text{if } t_g - t_i > 0 \\ t_i - t_g, & \text{else} \end{cases} \dots\dots\dots (4.2)$$

式中, t_i 为实际行人过街所用时间或行人过街理论所需时间。

可见, 传统计算行人过街时间方法应用有一定的局限性。当 $t_i < t_g$ 时, 行人过街时间过长, 会增加下一相位机动车延误; 当 $t_i > t_g$ 时, 行人过街时间过短, 有行人滞留现象, 增加行人延误。

另一方面, 由公式 (4.1) 可知, 计算行人过街时间过程输入参量较多, 对计算结果准确率影响复杂。一些参数需要手动取值, 且范围浮动较大, 有些参数随早晚高峰时

间段不同取值大幅变化，不具备算法的普适性要求。这也是造成计算行人过街时间偏差的主要原因。

4.2 行人过街信号优化模型

4.2.1 行人过街信号优化相关因素

行人过街信号优化需要考虑待过街行人等待区能容纳的行人数量 N 、待过街行人最大忍耐时间 T_1 、机动车最短绿灯时间 T_0 、行人最小绿灯时间、行人最大绿灯时间等因素，以确定何时启亮行人绿灯以及绿灯时间长度。

等待区域人数超过一定数量时，会对机动车交通以及行人安全造成影响，区域大小及容纳人数应根据实际情况确定。待过街行人最大忍耐时间与机动车交通状态有关，可根据机动车交通量与行人最大忍耐时间的关系以及实时交通量来确定，它应该作为此刻机动车的最大绿灯时间。机动车最短绿灯是为了保证交通安全和效率，而规定的机动车最小绿灯时间。行人最短绿灯时间是根据道路交通条件，为保证行人安全，设置的最小绿灯时间。行人最大绿灯时间，实际上就是机动车最大红灯时间，需要根据实时交通流量以及道路交通条件来确定，以确保机动车排队不上溯等。

当等待区域人数达到一定数量，且机动车绿灯时间 $G_{\text{车}}$ 超过机动车最小绿灯时间，应启亮行人绿灯，否则应根据当前行人忍耐时间确定绿灯启亮时刻。根据道路交通条件和交通流量，确定了行人最小绿灯时间及最大绿灯时间后，需要根据等待区域内的行人数量，来确定绿灯启亮后的延续时间，即绿灯时间。

4.2.2 基于 SVR 的行人过街时间估计

根据对有信号控制行人过街实际场景的观测发现，行人过街时间通常与待过街行人数量之间存在密切联系。本文利用 SVR 分析方法，构造过街行人数量与过街时间关系的目标函数，以便利用视频检测人数获取行人过街所需绿灯时间。

4.2.2.1 建立 SVR 平台

SVR 是支持向量机的一种特殊形式，SVM 是对输入的未知数据按照分类规则进行单分类，双分类或者多分类操作，而 SVR 是对 SVM 分类类别的无限扩大。本文行人数量与过街时间呈现高达几十种分类关系，SVM 无法完成分类工作，SVR 则能够对多种分类关系建立复杂的拟合函数，输出预测结果。

首先通过真实数据调查统计，建立模型样本空间，即模型训练学习的样本集。本文以长春市亚泰大街快速路为例，调查信号控制路段行人过街数量与时间数据信息。图 4.4 为该路段过街行人数量与时间关系图。




图 4.4 过街行人数量与时间关系图

与第三章建立待过街行人计数模型一致，通过调查得到的行人数量作为样本数据集，对应行人过街时间作为样本标签集，作为样本集参与 SVR 时间模型的训练学习过程。在此过程中，对 SVR 类型以及核函数分别进行遍历验证，择优确定相关参数，构造表达函数，最终得到的行人过街时间估计方法，预测待过街行人所需过街时间。本文行人过街时间估计方法专项设计思路如下。




图 4.5 行人过街时间估计方法专项设计思路图

模型设计分为两大部分，第一部分是模型的训练过程，样本集作为已知参与输入运算，直到 SVR 模型训练完成仅作为初始化应用。第二部分是预测行人过街时间，由上章节待过街行人计数算法获得实时人数，在预测部分作为唯一输入参量，经过第一部分训练的模型运算得到预测结果。

4.2.2.2 分时训练机制

(1) 过街用时差异

考虑到相同路段在一天不同时间行人出行目的的差异较大，通过实际调查发现，早

晚高峰时间段行人过街时间相对平峰时段过街时间较短，过街时间相差数秒，若平峰时段仍采用用于高峰时段训练的 SVR 模型，会造成行人过街时间估计较大偏差，不符合视频检测设备设计要求。因此需要对历史行人过街时间采取分时训练机制，将训练学习得到的 SVR 模型进行标号，在行人过街时间预测时，随系统时间自动选取相应标号的 SVR 模型。

(2) 过街数量差异

调查中发现，平峰时段行人过街平均用时不仅有所增加，而且行人数量明显少于高峰时段人数，这与高峰时段的模型适用条件截然不同。从实质来看，因为构成模型表达函数的历史样本数据差异巨大，造成目标函数结构不同。即便行人过街时间没有变化，而行人过街数量的样本标签取值范围不同，也会对目标函数造成影响。因此，需要对行人过街时间进行分时训练，建立完善的预测模型。

综合考虑以上两点，不同时段行人过街时间与数量的差异，本文对不同时段历史样本分别进行训练学习，构建 SVR 模型。本文分时训练机制思路设计图如图 4.6 所示。




图 4.6 分时训练模型图

4.2.2.3 SVR 参数优选

根据模型性质和用途，输入量为人数，输出量为预测时间，输入输出量为不同单位的数据，因此不是用来实现 SVM 分类算法，而是作为回归拟合应用。在上章节已经详细阐述两种回归分析方法，分别是 ε -SVR 和 ν -SVR，以及四种核函数，分别是线性核函数、多项式核函数、RBF 核函数和 Sigmoid 核函数，在此不再赘述，仅作为参数寻优过程，遍历组合排列方式进行优选。参数寻优保证该模型能够以最优目标函数表达

复杂的拟合过程，确保本文基于 SVR 的行人过街时间估计方法具备优良性能。表 4.1 以均方误差(mean squared error)和平方相关系数(squared correlation coefficient)作为模型性能评价指标。

表 4.1 不同参数下 SVR 过街时间模型性能

SVM 类型	核函数	Mse	Scs
ε -SVR	线性	3.20688	0.922648
	多项式	13.75410	0.716167
	RBF	1.43661	0.965403
	Sigmoid	3.34052	0.921386
v-SVR	线性	3.29270	0.922648
	多项式	16.29020	0.716167
	RBF	2.91279	0.930000
	Sigmoid	3.40970	0.920614

由此可知，类型 ε -SVR 与 RBF 核函数组合，均方误差最小，相应平方相关系数最大，自我学习正确率达 96.5%。即反映预测实际行人过街时间的误差波动最小，预测结果正确率最高。理论上能够通过视频检测设备准确地计算行人最佳过街时间。

交叉验证结果如图 4.7 所示。




图 4.7 样本集自学习交叉验证结果图

至此，本文算法能够根据行人数量确定合理的行人过街时间。当行人以不同到达率到达人行道 q_i ，等待过街时间 t_0 一定时，过街行人数量 n ($n=q_i*t_0$) 必然发生变化，导致过街时间因此发生变化，本文行人过街时间估计方法能够有效判断当前行人过街所需时间。极端情况下，当检测到无行人过街时，该模型配置行人过街时间为零，最大程度减少机动车延误的产生。

本文方法的行人过街区域人数变化图如图 4.8 所示。




图 4.8 本文方法行人过街区域人数变化图

4.3 实验效果分析

实验选取了位于长春市亚泰大街有信号控制行人过街路段，人行横道长度 30 米，宽度 6 米。以过街时间相对误差和绝对误差作为评价指标，对比传统计算行人过街时间模型，验证本文算法有效性。实验依托于 CPU Intel Core i5, 2.67GHz，内存 3.5GB 的 PC 环境下开发测试，软件采用 MATLAB 和 LIBSVM 工具包建立本文基于 SVR 的行人过街时间估计方法，所用视频及图像均为 640*400 分辨率。

4.3.1 行人过街时间估计效果

实验内容选择了高峰时段与平峰时段进行行人过街时间估计，高峰时段的实验视频为早 6 点到 8 点之间共 50 个信号周期的行人绿灯时间，平峰时段的实验视频为 13 到 15 点之间共 50 个信号周期的行人绿灯时间。实验中训练样本为不同日期同一时间段数据，避免预测数据与历史样本数据过于“相似”，造成时间估计准确度高的假象。

(1) 高峰时段行人过街时间估计

本文高峰时段基于 SVR 的行人过街数量与时间关系图如图 4.9 所示。




图 4.9 高峰时段行人过街数量与时间关系图

本文在高峰时段 50 个信号周期内进行行人过街时间估计，通过实地调查，高峰时段 q_p 为 0.25 p/s, s_p 为 0.5p/s.m, v_p 为 1.4m/s, C 为 136s, l 为 2s。

图 4.10 显示实际行人过街时间、传统模型计算行人过街时间以及本文方法预测行人过街时间。




图 4.10 高峰时段预测行人过街时间图

(2) 平峰时段行人过街时间估计

本文平峰时段基于 SVR 的行人过街数量与时间关系图如图 4.11 所示。




图 4.11 平峰时段行人过街数量与时间关系图

本文在平峰时段 50 个信号周期内进行行人过街时间估计，通过实地调查，高峰时段 q_p 为 0.16 p/s, s_p 为 0.5p/s.m, v_p 为 1.3m/s, C 为 136s, l 为 2s。

图 4.12 显示实际行人过街时间、传统模型计算行人过街时间以及本文方法预测行人过街时间。




图 4.12 平峰时段预测行人过街时间图

4.3.2 性能评价

本文行人过街时间估计方法以相对误差最大值(REM)、绝对误差最大值(AEM)、平均绝对误差(MAE)和平均绝对百分比误差(MAPE)作为模型性能评价指标, 分别对不同时段进行实验分析, 验证模型有效性。评价指标见公式 (4.3) ~ (4.6)。

$$REM = \max\left(\frac{T_p(i) - T_r(i)}{T_r(i)} \times 100\%\right), \quad i = 1 \cdots n \quad (4.3)$$

$$AEM = \max(T_p(i) - T_r(i)), \quad i = 1 \cdots n \quad (4.4)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |T_p(i) - T_r(i)|, \quad i = 1 \cdots n \quad (4.5)$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{T_p(i) - T_r(i)}{T_r(i)} \right| \times 100\%, \quad i = 1 \cdots n \quad (4.6)$$

式 (4.3) ~ (4.6) 中, n 为预测总次数; i 为行人第 i 次过街行为; $T_p(i)$ 为预测行人过街时间; $T_r(i)$ 为实际行人过街时间。高峰时段行人过街时间估计方法绝对误差对比图如图 4.13 所示。




图 4.13 行人过街时间绝对误差对比图 1

平峰时段行人过街时间估计方法绝对误差对比图如图 4.14。




图 4.14 行人过街时间绝对误差对比图 2

行人过街时间估计性能对比评价结果如表 4.2 所示。

表 4.2 行人过街时间估计性能对比评价

方法	时段	MAE	AEM	MAPE	REM	平均耗时
传统模型	高峰	3.91s	7.75s	13.40%	28.70%	—
	平峰	3.33s	11.33s	12.22%	53.95%	—
本文方法	高峰	1.93s	-4.67s	6.14%	16.68%	3.663ms
	平峰	1.79s	-3.85s	5.81%	-11.31%	3.412ms

通过表 4.2 分析，传统行人过街时间模型不能考虑到平峰时间段人数较少时的行人过街时间，行人绿灯时间空放现象严重，造成相对误差最大值高达 53.95%，本文方法高峰时段相对误差最大值为 16.68%，低于对比算法的 28.70%。本文过街时间估计方法

的各个时段平均相对误差均在 10%以内，平均绝对误差和绝对误差最大值均低于传统模型计算的行人过街时间，且计算机处理耗时完全满足实时性应用要求。本文行人过街时间估计方法实验效果较好，能够在不同周期内自适应估计行人过街所需时间，精度满足工程应用要求。

4.4 小结

本章主要分析了过街行人数量与过街时间关系，利用支持向量回归原理，建立了行人过街时间估计方法，经过初始化设定后，该模型能够自动根据当前等待过街区域的人数，有效预测行人穿越人行道所需时间。最后，通过实例验证，证明本文方法有效性，并对过街时间估计性能进行评价。

第5章 总结与展望

5.1 研究结论与成果

本论文依托于省科技厅重点项目——基于视频的行人过街信号智能优化技术研究，系统地研究了依靠视频检测技术，在有行人信号控制路段，预测当前待过街人群穿越人行道所需时间，为相关信号配时工作提供参考依据，保障行人过街安全，减少行人延误，提高城市运行效率。论文在此研究基础上，获得了以下研究成果：

(1) 改进了基于 kalman 的自适应背景更新算法

本文解决了背景差方法中背景无法及时更新的问题，在原有大津算法基础上，提出了双阈值概念，具备更强的分辨前景行人和背景的性能，真实还原背景图像。同时针对背景受环境影响发生突变现象，本文提出的强制背景更新方法，有效解决了背景“漂移”问题。这些改进对后续高层算法模块的稳定性提供可靠保证。

(2) 提出了基于行人密度判别的行人过街数量检测算法

本文行人过街数量检测算法在传统像素点特征和纹理特征基础上，预先对图像进行密度粗略估计以及采取分块模式操作，使不同密度阈值下的图像分别进行不同特征表达，从而达到较高的特征识别率。最后，通过 SVR 行人计数算法训练、学习，以此获得准确率较高的待过街行人数量。

(3) 提出了基于 SVR 的行人过街时间估计方法

本文利用支持向量回归原理作为行人过街时间估计的核心算法，针对满足行人过街时间需求，考虑行人过街数量与时间的关系，结合历史数据构建了行人过街时间估计方法，避免类似传统方法需要手动设定较多行人参数的过程。为了验证论文方法的有效性，对预测行人过街时间值与真实值进行对比实验，评价行人过街时间估计性能。

5.2 研究展望

智能交通是交通行业发展的必然趋势，依靠视频检测技术带动智能交通领域逐步走向成熟。本文行人计数算法和行人过街时间算法同样利用视频检测技术得以应用，虽然已经获得较好的检测准确率，但是在工程应用上仍然存在某些弊端，以下为下一步工作需要研究并解决的问题：

(1) 在实现行人计数与预测过街时间过程之前，需针对该场景进行模型训练过程，一旦更换应用场景，需要重新初始化。本文作者努力补充算法，使其能够自行训练，日后将减少诸多工作量。

(2) 随着训练样本变得日益陈旧，SVR 模型可能不适应新环境的变化，造成估计偏差。本文作者尝试改进算法，引入在线学习模块，保证模型可靠运行。

参考文献

- [1] 杜娟. 人群的密度估计与运动估计[D]. 大连: 大连理工大学, 2006.
- [2] 陈鸿. 重点视频监控区域的人群密度估计改进算法的研究与实现[D]. 南京: 南京邮电大学, 2013.
- [3] 谢鹏程. 复杂场景下实时监控中人群密度估计的研究与实现[D]. 成都: 电子科技大学, 2011.
- [4] 李志慧, 张长海, 曲昭伟, 等. 交通流视频检测中背景初始化算法[J]. 吉林大学学报: 工学版, 2008, 38(1): 148-151.
- [5] 叶锋, 范曼曼, 郑子华, 等. 一种改进的基于平均背景模型的运动目标检测算法[J]. 福建师范大学学报: 自然科学版, 2011, 27(4): 44-49.
- [6] 张秋仙. 帧间差分法与平均背景法在运动检测中应用的研究[J]. 企业科技与发展: 下半月, 2010 (9): 59-60.
- [7] Wang F, Dai S. Adaptive background update based on mixture models of Gaussian[C]//Information and Automation, 2009. ICIA'09. International Conference on. IEEE, 2009: 336-339.
- [8] 李明之, 马志强, 单勇, 等. 复杂条件下高斯混合模型的自适应背景更新[J]. 计算机应用, 2011, 31(07): 1831-1834.
- [9] Scott J, Pusateri M A, Cornish D. Kalman filter based video background estimation[C]//Applied Imagery Pattern Recognition Workshop (AIPRW), 2009 IEEE. IEEE, 2009: 1-7.
- [10] Kamel S, Ebrahimnezhad H, Ebrahimi A. Moving object removal in video sequence and background restoration using kalman filter[C]//Telecommunications, 2008. IST 2008. International Symposium on. IEEE, 2008: 580-585.
- [11] Sheng Z, Cui X. An adaptive learning rate GMM for background extraction[C]//Computer Science and Software Engineering, 2008 International Conference on. IEEE, 2008, 6: 174-176.
- [12] 赵发科, 施毅. 车辆跟踪中的背景初始化与更新方法研究[J]. 交通信息与安全, 2009 (004): 16-21.
- [13] Moeslund T B, Hilton A, Krüger V, et al. Visual analysis of humans[M]. Springer, 2011.
- [14] 苏松志, 李绍滋, 陈淑媛, 等. 行人检测技术综述[J]. 电子学报, 2012, 40(4): 814-820.
- [15] 张阳. 复杂交通场景中基于视频的行人检测与跟踪若干关键问题研究[D]. 广州: 华南理工大学, 2013.
- [16] 吕敬钦. 视频行人检测及跟踪的关键技术研究[D]. 上海: 上海交通大学, 2013.

- [17] Marana A N, Velastin S A, Costa L F, et al. Automatic estimation of crowd density using texture[J]. Safety Science, 1998, 28(3): 165-175.
- [18] Oren M, Papageorgiou C, Sinha P, et al. Pedestrian detection using wavelet templates[C]//Computer Vision and Pattern Recognition, 1997. Proceedings, 1997 IEEE Computer Society Conference on. IEEE, 1997: 193-199.
- [19] Viola P, Jones M. Fast and robust classification using asymmetric adaboost and a detector cascade[J]. Advances in Neural Information Processing System, 2001, 14.
- [20] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on. IEEE, 2005, 1: 886-893.
- [21] Sabzmeydani P, Mori G. Detecting pedestrians by learning shapelet features[C]//Computer Vision and Pattern Recognition, 2007. CVPR'07. IEEE Conference on. IEEE, 2007: 1-8.
- [22] Barinova O, Lempitsky V, Kholi P. On detection of multiple object instances using hough transforms[J]. Pattern Analysis and Machine Intelligence, IEEE Transactions on, 2012, 34(9): 1773-1784.
- [23] DONOHO D L. Denoising by Soft Thresholding[J].IEEE Tranction on IT,1995,41(03):613-627.
- [24] 胡宏宇, 关可汗, 李志慧, 曲昭伟. 考虑特征空间分布的行人数量估计方法[J]. 长安大学学报: 自然科学版, 2015, 35(S): 54-58.
- [25] 李寅, 王贵锦, 林行刚. 结合局部和全局特征的人群密度估计算法[J]. 清华大学学报: 自然科学版, 2013(4): 542-545.
- [26] 刘福美, 黎宁, 张燕, 等. 一种基于图像处理的人群密度估计方法[J]. 计算机与数字工程, 2011, 39(5): 118-122.
- [27] Wu B, Nevatia R. Detection of multiple, partially occluded humans in a single image by bayesian combination of edgelet part detectors[C]//Computer Vision, 2005. ICCV 2005. Tenth IEEE International Conference on. IEEE, 2005, 1: 90-97.
- [28] 岳晓娟. 智能监控系统的人群密度检测算法研究[D]. 哈尔滨: 哈尔滨工业大学, 2013.
- [29] 覃勋辉, 王修飞, 周曦, 等. 多种人群密度场景下的人群计数[J]. 中国图像图形学报, 2013, 18(4): 392.
- [30] 徐良杰, 王炜. 信号交叉口行人过街时间模型[J]. 交通运输工程学报, 2005, 5(1): 111-115.
- [31] ALHAJYASEEN W, NAKAMURA H. Modeling and analysis of pedestrian flow at signalized crosswalks[J]. 土木計画学研究・論文集, 2009, 26(4).

- [32] 刘光新, 李克平, 孙剑. 信号控制交叉口行人过街等待时间研究[J]. 中国安全科学学报, 2009, 19(9): 159-166.
- [33] 赵韩涛, 郭栋. 有行人专用相位交叉口行人过街时间模型[J]. 哈尔滨工业大学学报, 2012, 44(8): 57-61.
- [34] 钟章建. 路段行人过街信号控制方法及实现[D]. 长沙: 长沙理工大学交通运输工程学院, 2009.
- [35] Viola P, Jones M. Robust real-time object detection[J]. International Journal of Computer Vision, 2001, 4: 34-47.
- [36] 胡彪, 龚晓峰. 基于改进背景差法的运动目标检测[J]. 计算机工程与设计, 2010 (17): 3841-3844.
- [37] Choi J M, Chang H J, Yoo Y J, et al. Robust moving object detection against fast illumination change[J]. Computer Vision and Image Understanding, 2012, 116(2): 179-193.
- [38] 叶锋, 范曼曼, 郑子华, 等. 一种改进的基于平均背景模型的运动目标检测算法[J]. 福建师范大学学报: 自然科学版, 2011, 27(4): 44-49.
- [39] 李明之, 马志强, 单勇, 等. 复杂条件下高斯混合模型的自适应背景更新[J]. 计算机应用, 2011, 31(07): 1831-1834.
- [40] 李了了, 邓善熙, 丁兴号. 基于大津法的图像分块二值化算法[J]. 微计算机信息, 2005, 21(8): 76-77.
- [41] Cucchiara R, Grana C, Piccardi M, et al. Statistic and knowledge-based moving object detection in traffic scenes[C]//Intelligent Transportation Systems, 2000. Proceedings. 2000 IEEE. IEEE, 2000: 27-32.
- [42] Choi J M, Yoo Y J, Choi J Y. Adaptive shadow estimator for removing shadow of moving object[J]. Computer Vision and Image Understanding, 2010, 114(9): 1017-1029.
- [43] 张红颖, 李鸿, 孙毅刚. 基于混合高斯模型的阴影去除算法[J]. 计算机应用, 2013, 33(1): 31-34.
- [44] Hussain N, Yatim H S M, Hussain N L, et al. CDES: A pixel-based crowd density estimation system for Masjid al-Haram[J]. Safety science, 2011, 49(6): 824-833.
- [45] Ma R, Li L, Huang W, et al. On pixel count based crowd density estimation for visual surveillance[C]//Cybernetics and Intelligent Systems, 2004 IEEE Conference on. IEEE, 2004, 1: 170-173.
- [46] Wu Z, Zheng H, Wang J. Pedestrian Counting Based on Crowd Density Estimation and Lucas-Kanade Optical Flow[C]//Image and Graphics (ICIG), 2013 Seventh International Conference on. IEEE, 2013: 471-476.
- [47] Velastin S A, Yin J H, Davies A C, et al. Automated measurement of crowd density and

- motion using image processing[C]//SEVENTH INTERNATIONAL CONFERENCE ON ROAD TRAFFIC MONITORING AND CONTROL, 26-28 APRIL 1994. PROCEEDINGS.(IEE CONFERENCE PUBLICATION 391). 1994.
- [48] 高程程, 惠晓威. 基于灰度共生矩阵的纹理特征提取[J]. 计算机系统应用, 2010, 19(6): 195-198.
- [49] 王雅琳. 基于灰度共生矩阵的人群密度估计算法研究[D]. 西安: 西安科技大学, 2013.
- [50] Ojala T, Pietikainen M, Harwood D. Performance evaluation of texture measures with classification based on Kullback discrimination of distributions[C]//Pattern Recognition, 1994. Vol. 1-Conference A: Computer Vision & Image Processing., Proceedings of the 12th IAPR International Conference on. 1994 (1): 582-585.
- [51] Ojala T, Pietikainen M, Harwood D. A comparative study of texture measures with classification based on featured distributions[J]. Pattern recognition, 1996, 29(1): 51-59.
- [52] Chang C C, Lin C J. Training v-support vector classifiers: theory and algorithms[J]. Neural computation, 2001, 13(9): 2119-2147.
- [53] Chang C C, Lin C J. Training nu-support vector regression: theory and algorithms[J]. Neural Computation, 2002, 14(8): 1959-1978.
- [54] Fine S, Scheinberg K. Efficient SVM training using low-rank kernel representations[J]. The Journal of Machine Learning Research, 2002, 2: 243-264.
- [55] Lin C J, Weng R C. Simple probabilistic predictions for support vector regression[J]. National Taiwan University, Taipei, 2004.
- [56] Boser B E, Guyon I M, Vapnik V N. A training algorithm for optimal margin classifiers[C]//Proceedings of the fifth annual workshop on Computational learning theory. ACM, 1992: 144-152.
- [57] 李娜. 路段行人过街信号与交叉口信号协调控制研究[D]. 南京: 东南大学, 2004.
- [58] 顾金刚. 路段行人过街信号设置方法及实例研究[D]. 长春: 吉林大学, 2010.
- [59] 路婷. 路段人行横道信号设置影响因素分析及控制方法研究[D]. 长春: 吉林大学, 2011.

作者简介

（一）作者简介

姓名	关可汗	出生日期	1989.4
性别	男	出生地	吉林省长春市
民族	满族	学位	硕士
学历	硕士研究生	联系方式	
经历	2012.9—2015.7 硕士 吉林大学交通学院 交通信息工程及控制 2008.9—2012.7 学士 长春理工大学电子信息工程学院 电子工程		

（二）科研及其他成果

1.攻读硕士学位期间发表的学术论文

- [1] 胡宏宇, 关可汗, 李志慧, 曲昭伟. 考虑特征空间分布的行人数量估计方法. 长安大学学报(自然科学版)(增刊), 2015. (EI 检索)
- [2] Zhaowei Qu, Yuzhou Duan, Xianmin Song, Hongyu Hu, Huanfeng Liu, and **Kehan Guan**. Capacity prediction model based on limited priority gap-acceptance theory at multilane roundabouts. Mathematical Problems in Engineering, 2014. (SCI 检索)

2.攻读硕士学位期间获奖情况

- [1] 2012-2013 年度吉林大学硕士研究生基本奖学金
- [2] 2013-2014 年度吉林大学硕士研究生基本奖学金
- [3] 2014-2015 年度吉林大学优秀研究生一等奖学金

3.攻读硕士学位期间参与项目情况

- [1] 国家高技术研究发展计划(863 计划):《基于多源融合的混合交通行人安全状态识别技术》
- [2] 吉林省科技厅项目:《基于视频的行人过街信号智能优化技术研究》

致 谢

短暂而又宝贵的研究生生涯即将结束，还记得刚入学的画面，如梦初醒般依稀浮现在眼前。在这三年时光里，我成长了许多，也收获了许多。无论是老师，还是同学，都给予了我莫大的关心、支持和帮助，在硕士论文完成之际，向他们表示深深的感谢。

本论文能够得以完成，首先要感谢导师曲昭伟教授。曲老师严谨治学的作风，儒雅豁达的处世哲学，在我人生道路上深深地影响着我。三年的学习生活中，曲老师给予了我极大的帮助，对论文的构思、研究内容的确定以及解决问题的方法提供了宝贵建议，更重要的是，教会我如何独立、创造性的思考，能够在未来工作中做到学以致用，这是我人生中的宝贵财富。在此，向曲老师表示由衷的感谢。

感谢交通控制实验室的李志慧副教授。李老师学识渊博，求真务实，在我研究专业领域悉心指导，鞭策我按时完成课题组任务，对我完成相关科研工作给予了很大帮助，也对我的论文内容进行了补充和完善。在此，向李老师表示由衷的感谢。

感谢交通控制实验室的胡宏宇老师。胡老师学术能力坚实，具有丰富的专业基础，平日指导我完成学习理论知识、软件编程工作，使我的科研能力大幅进步，具备了良好的编程能力。在此，向胡老师表示由衷的感谢。

感谢课题组的陈永恒老师，宋现敏老师，陶鹏飞老师和魏巍老师，感谢他们所给予我的许多无私帮助以及为营造和睦、融洽的学术氛围所作出的努力。

感谢别一鸣博士、邢岩博士、江晟博士，感谢你们在我硕士生活中给我的帮助和指导。

感谢魏福祿博士、段宇洲博士、胡金辉硕士、陈利刚硕士、朱自博硕士、赵欢硕士、柴婷婷硕士、梁士栋硕士、王新慧硕士，感谢你们在我硕士的学习和生活中给予的宝贵建议和帮助。

感谢我的同窗好友徐谦硕士、张虎硕士、尉明丽硕士、刘岩硕士、李晓文硕士、修桂红硕士、赵鑫硕士、苗海芳硕士、王伟硕士、梁红梅硕士，赵忠浩硕士，常孝宁硕士、李伟硕士，感谢三年里有你们的陪伴，感谢这三年来对我的帮助和支持。

感谢研二、研一的杨秋杰硕士、刘焕峰硕士、陈明涛硕士、朱晓晴硕士、李汝志硕士、曹宁博硕士、李燕飞硕士、马佳磊硕士、白乔文硕士、孙磊硕士、李达修硕士，感谢你们在我论文完成过程中提供的帮助，你们的到来为交通控制实验室注入了新的活力，你们的到来也使我的学习生活变得更精彩。

特别感谢我的父亲母亲，是他们含辛茹苦将我培养成人，是他们在背后默默支持我、鼓励我，是我不断进步的动力。正是由于他们，使我在任何困难面前都能有勇气坚持下去！

最后，再次向曾经给予我帮助和鼓励的老师、家人、师兄、师姐、同学们致以我最崇高的敬意，愿你们身体健康，万事如意！

关可汗

2015年3月22日 于长春